

Thought for 2m 7s

A continuación te devuelvo un **informe técnico** (estilo corporativo) simulando un pipeline **Landing → Staging → Curated** para tu dataset **Randstad Q3 2025 Argentina** (8 columnas, 5.466 filas).

**Importante:** no corrijo datos; primero **diagnostico** y propongo **reglas sistemáticas**.

---

## 0) Perfilado rápido del dataset (foto inicial)

### Columnas detectadas

- Período (object): 1 valor → **2025-Q3** (formato OK con patrón YYYY-Qn)
- Departamento (object): 14 valores
- Industria (object): 13 valores
- Cargo (object): 145 valores
- Especialidad (object): 16 valores
- Región (object): 6 valores
- Sueldo\_Min (float)
- Sueldo\_Max (float)

### Checks de integridad básica (observado)

- Nulos: **0** en todas las columnas.
- Sueldo\_Min > Sueldo\_Max: **0 casos**.
- Valores <= 0 en sueldos: **0 casos**.
- Duplicados exactos de fila: **0**.

### Señales de calidad relevantes (observado)

- **Inconsistencias semánticas/categóricas** en Industria (detalle en Staging).
  - **Convenciones de casing** poco estandarizadas en Departamento e Industria (minúsculas/Mayúsculas mezcladas).
  - **Sueldos con decimales** frecuentes (0.25, 0.5, 0.75, etc.), típico de Excel por prorrateos o cálculos.
- 

## 1) Landing – Validación inicial (al recibir el dataset)

### 1.1 Validaciones básicas que ejecutaría (antes de transformar)

#### Estructura y contrato

- Validar **esquema esperado**: columnas obligatorias, nombres exactos (incluyendo tildes), orden no crítico pero sí presencia.

- Validar **cardinalidades esperadas**:
  - Período debería ser 1 (o un set controlado).
  - Región debería pertenecer a un catálogo (NEA/NOA/etc.).
- Validar **dominios**:
  - Sueldo\_Min y Sueldo\_Max numéricos, no texto con separadores raros.
  - Sueldo\_Min <= Sueldo\_Max.
  - Sueldo\_Min > 0.

#### Checks de sanidad del contenido

- Detección de “valores vacíos encubiertos”: "", " ", "-", "N/A", "s/d".
- Detección de caracteres invisibles: espacios dobles, tabs, NBSP (\u00A0) especialmente si viene de PDF.
- Reglas de unicidad (si aplica): en este caso **no hay una PK natural**, pero sí puedo definir una **clave de registro** candidata:
  - (Período,Región,Industria,Departamento,Especialidad,Cargo) debería ser “casi única” (si no lo es, lo reporto).

#### Trazabilidad

- Hash del archivo (MD5/SHA) + fecha/hora de ingesta + fuente + versión (Q3 2025) para auditoría.

## 1.2 Riesgos típicos si proviene de Excel/PDF

### Excel

- Tipos inconsistentes: números como texto, separadores ./, y formatos regionales.
- Decimales “raros” por fórmulas o redondeos intermedios.
- Celdas combinadas, encabezados multinivel, filas “comentario” o notas al pie.

### PDF

- Columnas corridas (shift), filas partidas, signos y tildes dañadas.
- Separadores de miles/decimales rotos, espacios invisibles, guiones.
- Duplicación por extracción (misma tabla repetida por página).

## 1.3 Controles mínimos antes de avanzar a transformación

- **Row count** esperado vs recibido (alerta si variación abrupta vs histórico).
- **Completeness** por columna (nulos + vacíos encubiertos).

- **Numeric sanity** en sueldos:
    - Min/Max, percentiles (P1/P99) para detectar escalas mal interpretadas (ej: 1.500.000 leído como 1500000 vs 1.5).
  - **Casing/encoding**: detectar texto con mojibake (ej: DÃa) aunque aquí no lo vi.
  - **Reporte de anomalías**: si pasa umbrales, el pipeline se frena (quality gate).
- 

## 2) Staging – Auditoría de Calidad (diagnóstico)

### 2.1 Inconsistencias en mayúsculas/minúsculas (observado)

#### Departamento (ejemplos reales)

- Predomina minúscula: adm & finanzas, it, rrhh, produccion, logistica
- Aparecen mayúsculas/Title: Minería, HYS

#### Industria (ejemplos reales)

- Mezcla de estilos: IT vs healthcare vs Minería

#### Riesgo

- En BI/Modelado esto rompe segmentaciones y produce “categorías duplicadas” visualmente.

#### Recomendación (regla sistemática)

- Definir convención única:
    - Opción A (más ejecutiva): **Title Case** + siglas preservadas (IT, RRHH, HYS).
    - Opción B (más técnica): **UPPER** para catálogos cortos (Departamentos/Regiones) y Title para Industrias.
  - Implementar vía **diccionario de estandarización** (no manual fila por fila).
- 

### 2.2 Duplicidades semánticas (observado)

#### Industria: duplicidad por abreviación / naming

Detecté un par **muy claro**:

- Banca & Serv Financieros
- Banca & Servicios financieros

#### Impacto

- Si modelás por industria: vas a tener **dos industrias** que son la misma.

#### Industria: solapamientos por “contenedor vs subcategoría”

Detecté casos donde un valor está “contenido” en otro:

- Minería y Gas, Petróleo y Minería

### Impacto

- Esto no es solo duplicidad: es **problema de taxonomía** (nivel jerárquico mezclado).
- Podés estar midiendo “Minería” dos veces en análisis comparativos (según cómo lo use el negocio).

### Recomendación (reglas sistemáticas)

- Crear **catálogo maestro de Industria** con:
  - Industria\_Canonica
  - Industria\_Nivel1 / Industria\_Nivel2 (si aplica)
  - Sinonimo\_Original (para mapear entradas)
- Resolver abreviaturas con reglas:
  - Serv → Servicios
  - Normalización de & y y
  - Normalización de tildes y casing
- Para el solapamiento de jerarquía: decidir una de estas políticas:
  - **Política 1:** Mantener “macroindustria” (Gas/Petróleo/Minería) y eliminar subcategorías del mismo nivel.
  - **Política 2:** Separar en 2 campos: Sector\_Energia + Subsector (Minería/Petróleo/Gas).

## 2.3 Problemas de tipificación (texto vs numérico)

### Sueldo\_Min / Sueldo\_Max

- Están numéricos, pero con **muchos decimales** (frecuentes .25/.5/.75). Esto suele ser Excel: prorrates, promedios o escalas con “cuartos”.

### Riesgo

- En SQL / DWH, si lo guardás como FLOAT podés tener:
  - Comparaciones raras
  - Agregaciones con “ruido” decimal
  - Inconsistencias al redondear en reportes

### Recomendación

- En Staging: conservar “tal cual” pero **tipar conscientemente**:
  - NUMBER(18,2) si se considera moneda con centavos

- o NUMBER(18,0) si la definición del negocio es “ARS enteros”
  - Agregar checks:
    - o Sueldo\_Min y Sueldo\_Max deben ser múltiplos de 1 o 0.01 según estándar.
    - o Si aparecen decimales “raros”, documentarlos como “fuente”.
- 

## 2.4 Outliers coherentes o sospechosos (observado)

### Distribución (aprox por percentiles)

- Sueldo\_Min: min ~0.95M | P50 ~3.78M | P95 ~10.15M | max ~19.27M
- Sueldo\_Max: min ~1.21M | P50 ~4.97M | P95 ~14.38M | max ~23.87M
- Ratio Max/Min: min ~1.07 | P95 ~1.69 | max ~2.07 (no hay ratios delirantes)

### Interpretación

- Los máximos aparecen en roles tipo **CFO / Director** y regiones como **Patagonia**, lo cual es coherente.
- No veo señales típicas de escala rota (ej: valores 100x).

### Recomendación (reglas de outliers)

- No “borrar outliers”: marcar.
  - Crear bandera:
    - o Flag\_Outlier\_P99\_Min, Flag\_Outlier\_P99\_Max
    - o o z-score/log-score por Cargo (más justo: el outlier de un junior no es el de un CFO)
- 

## 2.5 Reglas sistemáticas de estandarización recomendadas (no manuales)

### Reglas de texto

- TRIM + colapso de espacios múltiples.
- Normalización de tildes (para matching) sin perder el original.
- Convención de casing.
- Reemplazos controlados (diccionario):
  - o Serv → Servicios
  - o & → y (o mantener & pero consistente)
- Mapeo por catálogo maestro (MDM liviano):
  - o Industria\_Original → Industria\_Canonica
  - o Departamento\_Original → Departamento\_Canonico

## Reglas de numéricos

- Tipado explícito y validación de rango por percentiles.
  - Sueldo\_Min <= Sueldo\_Max como constraint lógico.
  - Auditoría de decimales: política de redondeo definida por negocio.
- 

## 3) Normalización Monetaria (ARS → USD)

### 3.1 ¿Conviene usar columna o medida para USD?

#### Recomendación profesional:

- En un DWH/Curated: **columna derivada en tabla de hechos** (o vista materializada) **solo si**:
  - tenés tipo de cambio versionado por fecha/período
  - necesitás performance y consistencia en consumo masivo
- En Power BI/semantic layer: **medida** suele ser mejor para flexibilidad:
  - permite elegir tipo de cambio (oficial/MEP/CCL)
  - permite “as-of date” y escenarios

#### Mi elección típica en corporativo

- Guardar en Curated: **ARS como moneda base** (si la fuente es ARS) + **FX\_KEY**
  - Calcular USD en semantic layer (medida) o en vistas con join a FX según necesidad.
- 

### 3.2 Riesgos de tipo de cambio fijo

- Rompe comparabilidad inter-períodos si más adelante sumás Q2/Q4.
  - Genera discusiones interminables (“¿por qué USD subió si ARS bajó?”) porque el FX no refleja timing.
  - Si hay auditoría: un número en USD sin FX trazable es una bomba con reloj.
- 

### 3.3 Alternativa profesional escalable

- Crear **dimensión de tipo de cambio**:
  - FX\_DATE o PERIODO
  - FX\_RATE
  - FX\_TYPE (Oficial / MEP / CCL)
  - SOURCE (BCRA, proveedor, etc.)

- En fact salarial: guardar PERIODO y usarlo para linkear FX:
    - $\text{Sueldo\_Min\_USD} = \text{Sueldo\_Min\_ARS} / \text{FX\_RATE}(\text{PERIODO}, \text{FX\_TYPE})$
  - Si tu consumo es “por trimestre”, podés usar **promedio trimestral** o **cierre del trimestre** pero definido por política.
- 

### 3.4 Buenas prácticas moneda dual

- Nunca mezclar en el mismo campo “ARS o USD” sin bandera.
  - Mantener:
    - CurrencyCode (ARS)
    - Amount\_ARC
    - Amount\_USD calculado con FX trazable (o medida)
    - FX\_Type, FX\_Rate, FX\_AsOfDate
  - En reporting: mostrar siempre el **FX usado** (tooltip o nota) para transparencia.
- 

## 4) Curated – Preparación para Modelado Analítico

### 4.1 Reglas adicionales antes de modelar (quality gates)

- Catálogos canónicos para:
    - Industria, Departamento, Región, Especialidad, Cargo
  - Definir una **clave técnica** (surrogate key) en la fact:
    - SalaryRecordSK (hash o secuencia)
  - Chequear unicidad lógica:
    - si  
(Período,Región,Industria\_Canonica,Departamento\_Canonico,Especialidad,Cargo) no es única, decidir:
      - ¿son múltiples fuentes?
      - ¿son múltiples seniorities no modelados?
  - Versionado:
    - si vas a incorporar Q2/Q4, necesitás Período como dimensión y no como texto suelto.
- 

### 4.2 Columnas derivadas recomendadas

#### De negocio

- $\text{Sueldo\_Mid} = (\text{Min} + \text{Max}) / 2$
- $\text{Sueldo\_Spread} = \text{Max} - \text{Min}$
- $\text{Sueldo\_Spread\_Pct} = (\text{Max} - \text{Min}) / \text{Min}$
- Band o Nivel si existe lógica de seniority (si no existe, no inventar, pero dejar preparado)

#### De calidad

- Flag\_Industria\_NoCanonica (cuando no matchea catálogo)
- Flag\_Decimales\_Inusuales (según política)
- Flag\_Outlier\_P99 por segmento (ej: por Cargo)

#### Técnicas

- RowHash (hash de columnas negocio) para detección de cambios si llega una nueva versión.

### 4.3 Métricas base a construir (para el modelo semántico)

- **Promedio salarial** (usando Midpoint, no promedio simple de Min/Max por separado)
- **Rango** (Spread) y **dispersión relativa** (Spread%)
- **Índices comparativos:**
  - Index por Región vs Total Argentina
  - Index por Industria vs Total
- **Top/Bottom:**
  - Top cargos por Mid
  - Industrias con mayor spread (mercados más “volátiles” salarialmente)

### 4.4 Advertencias analíticas relevantes

- Este dataset es **bandas** (min/max), no “salarios observados”. Promediar bandas puede inducir sesgo si la distribución real no es uniforme.
- Mezcla de taxonomías (Industria macro vs subindustria) puede invalidar comparaciones si no se normaliza.
- Si vas a comparar períodos, necesitás:
  - FX trazable para USD
  - y, si querés “real”, ajuste por inflación (otro layer, otro debate).



### Entregable sugerido (arquitectura de tablas)

- **Landing:** L\_RANDSTAD\_SALARIOS\_RAW (tal cual)
  - **Staging:**
    - S\_RANDSTAD\_SALARIOS\_TYPED (tipos + flags + profiling)
    - S\_CAT\_INDUSTRIA\_MAP (original → canónica)
  - **Curated:**
    - DIM\_PERIODO, DIM\_REGION, DIM\_INDUSTRIA, DIM\_DEPARTAMENTO, DIM\_CARGO, DIM\_ESPECIALIDAD
    - FACT\_SALARY\_BANDS (Min/Max/Mid/Spread + SKs + FX\_KEY opcional)
- 

Si querés, en el próximo paso te lo bajo a algo aún más “implementable”:

1. **lista exacta de tests** tipo Great Expectations/dbt tests (not\_null, accepted\_values, relationships, unique combinación), y
2. un **modelo estrella propuesto** (con granularidad y claves) listo para Power BI/Snowflake.