

UNIDAD 2: MANIPULACIÓN DE DATOS

1. Estructura de los Datos

- **Datos:** Son piezas de información referentes a algún tema o área en particular. Según su organización interna, se clasifican en tres formas:
- **Datos Estructurados:** Poseen un **formato estandarizado o definido** que permite tanto al software como a las personas acceder a la información de manera eficiente. Se organizan típicamente en **tablas compuestas por filas (registros) y columnas (atributos)**. Cada campo tiene un tipo de dato y formato claro. Sus características principales son:
 - **Atributos definibles:** Todos los registros comparten los mismos atributos.
 - **Atributos relacionales:** Poseen información común que permite **vincular o conectar entre sí diferentes conjuntos de datos**.
- **Almacenamiento:** Se guardan de forma conveniente en **Bases de Datos Relacionales** y se administran/consultan sencillamente mediante el lenguaje **SQL (Structured Query Language)**.
- **Datos No Estructurados:** Información que **no posee un modelo de datos predefinido ni un esquema fijo**, y cuya organización interna no sigue una estructura tabular (no se pueden representar naturalmente mediante filas y columnas). Ejemplos típicos: correos electrónicos, chats, documentos de texto, imágenes, audio y video. Se estima que representan **más del 80% de los datos generados a nivel mundial**.
- **Datos Semi-estructurados:** Representan una categoría intermedia. Tienen **cierta organización interna**, pero no siguen un esquema rígido como las tablas de una base relacional. Utilizan **etiquetas (tags) o pares clave-valor** para dar estructura con flexibilidad. Los formatos principales son:
 - **XML (Extensible Markup Language):** Basado en texto, fácil de leer para humanos y computadoras. Utiliza **tags** que pueden ser **elementos** (ej. `<FirstName>`) o **atributos** (ej. `Age="23"`). Los elementos pueden tener elementos secundarios o "hijos" para expresar relaciones jerárquicas. Históricamente usado en integración de sistemas, pero es **muy verboso y complejo** para la legibilidad humana.
 - **JSON (JavaScript Object Notation):** Formato de archivo liviano basado en JavaScript, utilizado para almacenar e intercambiar datos. Se estructura en ****pares clave-valor** e indica su jerarquía mediante llaves `{}` y listas mediante corchetes `[]*`. Es el estándar actual para APIs e intercambio web.
 - **YAML (YAML Ain't Markup Language):** Lenguaje de serialización enfocado en una **gran legibilidad humana**. Su estructura se define exclusivamente por la **separación de líneas e indentación**, eliminando la dependencia de caracteres especiales. Ampliamente utilizado en archivos de configuración.

2. Almacenamiento de Datos Tabulares

- Aunque la gran mayoría de los datos del mundo real no son estructurados, en Ciencia de Datos es común trabajar con **datos tabulares** (filas y columnas). Los formatos de almacenamiento físico se dividen según su orientación en memoria:
- **Archivos Orientados a Filas:** Los datos se organizan en registros completos, guardando todos los datos asociados a un registro juntos en memoria. Realizar consultas sobre el valor de un solo atributo para muchos registros es **ineficiente**, ya que se debe cargar en memoria todo el registro con datos innecesarios.
- **CSV (Comma-Separated Values):** Formato orientado a filas donde los registros se separan por saltos de línea y los atributos por comas, puntos y comas o tabulaciones. Es de los más usados, pero **no guarda información del tipo de dato** (todo se almacena como texto simple).
- **TXT:** Almacenamiento simple de texto. Cuando guarda datos tabulares es similar al CSV, y se usa comúnmente en **Procesamiento de Lenguaje Natural (NLP)** para guardar transcripciones, documentos o registros médicos.
- **Archivos Orientados a Columnas:** Los datos se organizan por columna, campo o variable, guardándose todos los datos de una misma columna juntos en memoria. Si se quiere consultar una sola columna, **solo se carga esa columna en memoria**, optimizando las consultas analíticas masivas. Además, al ser todos los datos del mismo tipo, permite una **mejor compresión del archivo**.
- **Apache Parquet:** Formato orientado a columnas **optimizado para grandes cargas de datos (Big Data)** y consultas analíticas eficientes. Desarrollado por Cloudera y Twitter en 2013 como proyecto de código abierto, es de uso común en ecosistemas como Hadoop, Hive, Impala y Spark.
- **HTML (HyperText Markup Language):** Utilizado principalmente en páginas web, en ciencia de datos sirve para almacenamiento estructurado o no estructurado. Su sintaxis de marcado delimita tablas mediante etiquetas clave: `<table>` (define inicio/fin), `<tr>` (fila), `<th>` (celda de encabezado) y `<td>` (celda de datos).

3. Data Wrangling y Reformateo de Datos

- **Data Wrangling:** Es el proceso de **preparar los datos y ponerlos en el formato necesario** para poder realizar un posterior análisis de los mismos.
- **Forma Ancha (Wide) vs. Forma Larga (Long):** Reformar un DataFrame consiste en su transposición entre estos formatos.
- **Forma Ancha (Wide):** Cada fila corresponde a una entidad única y el identificador principal (`id`) **no se repite**. Las mediciones repetidas o variables similares se disponen en columnas independientes.
- **Forma Larga (Long):** Cada fila representa una **observación individual**. Implica una fila por cada combinación de entidad y atributo. El identificador `id` **aparece repetido**, por lo que deja de ser suficiente por sí solo para identificar un registro de forma única.
- ****Operación `pd.melt()`** :** Método de Pandas para transformar una tabla de **formato ancho a formato largo**. Permite agrupar varias columnas en una sola, produciendo un DataFrame más largo. Se configuran parámetros esenciales como `id_vars` (columnas identificadoras que se mantienen fijas) y `value_vars` (columnas que se van a despivotar).

4. Manejo de Datos Faltantes

- La presencia de datos faltantes (**NaN**) está ligada a errores de recolección, elaboración de la base o a campos que legítimamente no aplican para un registro. Deben identificarse y tratarse obligatoriamente antes de cualquier análisis o modelado, ya que **pueden afectar drásticamente los resultados, estimaciones y conclusiones**.
 - Estrategias fundamentales de tratamiento:**
- Eliminación de registros:**
 - dropna()** : Por defecto, elimina cualquier fila del DataFrame que contenga, al menos, un valor faltante.
 - **Argumento how='all'**** : Elimina únicamente los registros que están **formados por completo por NaN**.
 - **Argumento axis='columns'**** : Aplica la misma lógica de eliminación pero sobre las columnas en lugar de las filas.
 - Precaución:** Es una estrategia sencilla pero **puede implicar la pérdida de información relevante**, especialmente si los faltantes no se distribuyen de forma completamente aleatoria.
 - Imputación de datos:** Consiste en "llenar" los huecos reemplazando los faltantes por valores posibles basados en ciertos criterios.
 - fillna()** : Función para reemplazar valores faltantes. Puede hacerse mediante una **medida resumen representativa general** (como la media o mediana de toda la columna) o mediante una **medida resumen segmentada** según variables categóricas (ej. imputar el precio promedio de las viviendas agrupado según su barrio usando `groupby('barrio')`).
 - Imputación por Interpolación:** Técnica que estima una función matemática a partir de los valores observados y la utiliza para predecir los faltantes. Se usa especialmente en datos con un **orden natural**, como series de tiempo o escalas continuas.
 - Interpolación Lineal:** La forma más sencilla; dados dos puntos observados vecinos, calcula una única recta que pasa por ellos para de esta manera estimar el valor faltante en ese intervalo.
 - Interpolación Polinómica:** Forma de interpolación global que busca un polinomio que pase por todos los puntos de la serie para obtener una ecuación que estime los valores faltantes.
 - Noción de cercanía:** No se limita a la distancia física; puede definirse bajo criterios de **cercanía espacial, pertenencia a un mismo segmento/clase o cercanía temporal**.

5. Combinaciones de Conjuntos de Datos

- Son operaciones realizadas entre diferentes datasets para ampliar la información disponible para el análisis. Métodos de Pandas:
- concat()** : Se utiliza para concatenar dos o más DataFrames a lo largo de un eje específico (horizontal con `axis=1` o vertical con `axis=0`). Por defecto aplica un **outer join** (mantiene todas las filas/columnas y rellena con NaN), pero puede cambiarse a **inner join** seteando el argumento `join='inner'` para conservar únicamente las columnas o índices compartidos.
- merge()** : Es la opción más común y flexible para combinar DataFrames basándose en una o más columnas compartidas que funcionan como llaves o **keys**. Es la operación análoga a los *joins* de bases de datos relacionales SQL. Parámetros críticos:
 - how** : Define el tipo de unión matemática (**inner**, **outer**, **left**, **right**, o **cross** para uniones cruzadas que devuelven todas las combinaciones posibles).
 - on** : Nombre de la columna para realizar la unión (debe estar en ambos datasets).
 - left_on** y **right_on** : Se usan si las columnas llave tienen nombres distintos en el DataFrame izquierdo y derecho.
- join()** : Se utiliza para combinar dos o más DataFrames en función de sus índices o columnas específicas a través del parámetro `on`. Por defecto realiza una unión de tipo left.

6. Funciones Auxiliares y Regular Expressions (Regex)

- Métodos Útiles de Pandas/Python:**
- .rename()** : Útil para renombrar columnas o índices.
- .str.replace()** : Reemplaza caracteres o cadenas dentro de una columna de texto.
- .str.strip()** : Elimina espacios en blanco al inicio y al final de las cadenas.
- .str.lower()** / **.str.upper()** : Convierte cadenas de texto a minúsculas o mayúsculas, respectivamente.
- .astype(tipo)** : Convierte el tipo de dato de una columna.
- .isnull()** / **.isna()** / **.notnull()** : Detectan valores faltantes devolviendo Series booleanas.
- .unique()** : Devuelve un array con los valores únicos de una columna.
- .value_counts()** : Devuelve una Serie con las frecuencias de los valores únicos.
- pd.to_datetime()** : Convierte valores almacenados como texto en objetos de tipo fecha-hora (`datetime64[ns]`), permitiendo operaciones temporales como ordenamiento, extracción de componentes (año, mes, día, hora) y cálculo de diferencias. Admite los argumentos `dayfirst=True` y `format` (ej. `format='%d/%m/%Y'`).

- **Módulo `datetime`**: Clasifica objetos temporales en **naive** (sin información de zona horaria) y **aware** (con información explícita de zona horaria, habitualmente configurados con la librería `pytz`).
- **Tipo de dato `object`**: En Pandas, las columnas de texto se representan como `object` (no `str`) para permitir la compatibilidad con cualquier objeto de Python y tolerar valores faltantes (`NaN`).
- **Expresiones Regulares (REGEX)**: Cadenas escritas según un lenguaje específico que describe un **patrón de búsqueda flexible** dentro de un texto. Se construyen con caracteres literales, secuencias o caracteres especiales (ej. `\d` matchea un dígito, `\D` matchea lo que no sea un dígito, `+` indica una o más ocurrencias).
- **Módulo `re` de Python**:
 - `re.search(pattern, string)`: Busca la primera ocurrencia del patrón y devuelve un objeto `match`.
 - `re.split(pattern, string)`: Parte la cadena en cada ocurrencia del patrón.
 - `re.findall(pattern, string)`: Devuelve todas las ocurrencias encontradas en forma de lista o tupla.
 - `re.sub(pattern, repl, string)`: Realiza reemplazos de las ocurrencias del patrón por el valor `repl`.
- **Método `.str.extract()` de Pandas**: Busca y extrae partes de una cadena que coincidan con los **grupos de captura** (definidos entre paréntesis `()`) de una regex, devolviendo una columna por cada grupo. Devuelve solo la primera coincidencia del patrón; para extraer todas se usa `.str.extractall()`.

UNIDAD 3: MEDIDAS RESUMEN Y CORRELACIÓN

1. Clasificación de Variables

- **Variable**: Característica, cualidad o propiedad observada que puede asumir diferentes valores y es susceptible de ser cuantificada o medida en una investigación. En formato largo, cada columna es una variable y cada fila es un registro. Se clasifican en:
 - **Cualitativas o Categóricas**: Variables que no son medibles numéricamente.
 - **Cuantitativas**: Toman valores numéricos para los cuales tiene sentido realizar operaciones aritméticas. Se dividen en:
 - **Continuas**: Pueden asumir teóricamente cualquier valor dentro de un intervalo.
 - **Discretas**: Solo pueden tomar valores aislados en dicho intervalo.

2. Medidas o Estadísticas de Posición

- Brindan información acerca de la **localización o centralidad** del conjunto de observaciones de una variable.
- **Media Aritmética ($\overline{X}$)**: Suma de todos los valores observados de la variable dividida por el número total de datos (n). Se calcula con el método `mean()` de Pandas. Al depender de todos los valores del registro, **es sumamente sensible a la presencia de observaciones anormalmente grandes o pequeñas (outliers)**, lo que puede distorsionar su representatividad.
- **Mediana (Q_2)**: Segundo cuartil o percentil 50. Es el valor de la variable que se encuentra exactamente en la **posición central** del conjunto de datos ordenados de menor a mayor. Divide al conjunto en dos partes iguales: el 50% de las observaciones son menores o iguales a ella y el otro 50% son mayores. Es una **medida robusta**, idónea cuando hay outliers presentes.
- **Media Truncada (Trimmed Mean)**: Promedio calculado sobre los datos una vez que se ha eliminado un cierto porcentaje fijo ($\alpha \cdot 100\%$) de las observaciones más pequeñas y más grandes del conjunto. Constituye una **medida de centralidad intermedia entre la media y la mediana**. Es el método oficial empleado en la evaluación de pruebas olímpicas de patinaje sobre hielo.
- **Fractilas o Cuantiles**: Estadísticas descriptivas de posición general. La fractila de orden r es aquel valor de la variable tal que el **$r\%$ de las observaciones del conjunto ordenado son menores o iguales a él**.
- **Cuantiles (Q_1, Q_2, Q_3)**: Dividen al conjunto de datos ordenados en **4 partes con aproximadamente el mismo número de datos (25% cada una)**.
- **Cuartil 1 (Q_1)**: Valor tal que el 25% de los datos son menores o iguales a él.
- **Cuartil 2 (Q_2)**: Valor tal que el 50% de los datos son menores o iguales. Coincide exactamente con la **mediana**.
- **Cuartil 3 (Q_3)**: Valor tal que el 75% de los datos son menores o iguales a él.
- **Cálculo en Pandas (`quantile()`)**: Permite calcular cualquier fractila especificando su orden decimal en el parámetro `q` (por default es 0.5). El parámetro `interpolation` define el método matemático de estimación. Por defecto, Pandas utiliza `interpolation='linear'`, conocido como el **Método R-7**.
- **Método R-7**: Calcula la posición teórica mediante:

$$Pos = 1 + Q(n - 1)$$

Si la posición arroja un valor decimal, la fractila se calcula tomando la parte fraccional (f) y las observaciones ordenadas de las posiciones enteras adyacentes (x_i y x_j , con $x_i \leq x_j$):

$$X_Q = x_i + f(x_j - x_i)$$

Otras opciones para el parámetro `interpolation` son: `'lower'` (toma x_i), `'higher'` (toma x_j), `'nearest'` (toma el más cercano) y `'midpoint'` (punto medio entre ambos).

- **Decilos y Percentilos:** Dividen el conjunto ordenado en 10 y 100 partes iguales, respectivamente. En NumPy se calculan con la función `percentile()`, expresando $\$q$ como porcentaje entero entre 0 y 100.
- **Moda:** Es el valor de la variable que **se presenta el mayor número de veces** (el de mayor frecuencia absoluta). En Pandas se obtiene con el método `mode()` (devuelve una Serie ya que un conjunto puede presentar más de una moda). Es la **única medida de posición que puede aplicarse a variables cualitativas o categóricas** (atendiendo a la codificación del diccionario de variables).

3. Medidas o Estadísticas de Dispersión

- Las medidas de posición resumen solo parte de la información. Dos conjuntos pueden compartir la misma media pero **diferir en cuánto se alejan del valor central**, surgiendo la necesidad de describir la variabilidad.
- **Rango:** Diferencia aritmética entre el máximo y el mínimo valor observado de la variable:

$$\text{Rango} = X_{\{\max\}} - X_{\{\min\}}$$

- **Variancia (S^2):** Medida de cuánto se desvían, en promedio, las observaciones respecto a la media aritmética:

$$S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \overline{X})^2$$

A mayor variabilidad, mayor es S^2 . Se calcula con `var()` en Pandas.

- **Desviación Estándar (S):** Definida como la raíz cuadrada positiva de la variancia. Posee la ventaja analítica de quedarexpresada en las mismas unidades originales de la variable, interpretándose directamente como una "distancia promedio de las observaciones con respecto a la media". Se calcula con `std()` en Pandas.
- **Coeficiente de Variación (CV):** Es la desviación estándar dividida por la media aritmética ($CV = S / \overline{X}$). Al ser una **medida adimensional**, indica qué proporción representa el desvío estándar de la media y se utiliza para comparar la variabilidad de dos o más conjuntos de datos que difieren en sus unidades de medida o magnitudes.
- **Rango Intercuartil (RI):** Diferencia matemática entre el tercer y el primer cuartil ($\text{RI} = Q_3 - Q_1$). Mide la dispersión del 50% de los datos centrales y **no está influenciado por valores extremos (es robusto)**, siendo la medida de dispersión adecuada para acompañar a la mediana.
- **Desviación Mediana Absoluta (MAD):** Versión robusta de la desviación estándar basada en la mediana. Se define como la **mediana de los valores absolutos de las diferencias entre cada observación y la mediana**:

$$\text{MAD} = \text{Mediana}(|X_i - Q_2|)$$

- ****El método `.describe()`**** : Devuelve de forma rápida gran parte de las métricas numéricas (`count`, `mean`, `std`, `min`, cuartiles y `max`). Si se aplica sobre datos de una variable cualitativa (tipo de dato `object` o categórico), arroja el conteo de registros válidos (`count`), cantidad de valores únicos (`unique`), la categoría más frecuente (`top`) y su frecuencia respectiva (`freq`).
- **El Boxplot (Diagrama de Caja):** Gráfico construido a partir del conjunto de cinco números (mínimo, Q_1 , mediana, Q_3 , máximo).
- **Boxplot Modificado:** Versión popularizada por John Tukey para detectar potenciales outliers (observaciones atípicas inusuales en el contexto de una variable).
- **Criterio de Outliers:** Se consideran potenciales outliers aquellas observaciones que caigan por fuera del intervalo:

$$[Q_1 - 1.5 \cdot \text{RI}, ; Q_3 + 1.5 \cdot \text{RI}]$$

En este gráfico, los bigotes o *whiskers* se extienden únicamente hasta las observaciones mínima y máxima que **no sean puntos atípicos**, marcando los outliers como puntos separados independientes.

- **Parámetros de Configuración:** En Seaborn `boxplot()`, setear `showfliers=False` oculta visualmente los outliers (como si no existieran). Modificar el parámetro `whis=[0, 100]` construye el boxplot clásico extendiendo los bigotes hasta los valores mínimo y máximo absolutos sin detectar outliers por separado.
- **Tratamiento de Outliers:** El error más común es eliminarlos automáticamente. Esto altera la distribución original y sesga los resultados, ya que en muchos fenómenos los extremos son válidos. Ante su detección, debe evaluarse si es un error de medición/carga (justificando su exclusión por ser físicamente imposible o una falla documentada) o si proviene del fenómeno real, ameritando conservar el dato analizando el escenario con/sin él, usando estadísticas robustas o métodos estadísticos diseñados para reducir su influencia.

4. Tablas de Frecuencias

- Constituyen una forma efectiva para resumir observaciones. Se implementan mediante el método `.value_counts()` combinándolo con `.reset_index()`, `.rename()` y ordenamientos como `.sort_index()`.
- **Componentes principales:**
- **Frecuencia Absoluta:** Número de veces que se presenta cada categoría o valor aislado en el dataset.
- **Frecuencia Relativa:** Cociente entre la frecuencia absoluta correspondiente y el número total de datos ($\$n$), oscilando siempre entre 0 y 1. Multiplicada por 100 expresa el **Porcentaje**.
- **Segmentación para Continuas:** Cuando se trabaja con variables cuantitativas continuas con un gran número de valores diferentes, se realiza un agrupamiento previo en subintervalos (segmentación) de igual amplitud mediante el método `pd.cut()` combinándolo con puntos de corte generados por `np.arange()`.
- **Frecuencias Acumuladas:** Calculadas utilizando el método `.cumsum()` de Pandas.
- **Frecuencia Absoluta Acumulada:** Número de observaciones de la variable menores al límite superior del subintervalo correspondiente.
- **Frecuencia Relativa Acumulada:** Cociente entre la frecuencia absoluta acumulada correspondiente y el número total de datos.

5. Métricas de Correlación

- **Análisis de Correlación:** Tiene como objetivo estudiar el **comportamiento conjunto de dos variables aleatorias X e Y**, es decir, el grado en que ambas varían o "cambian" conjuntamente.
- **Gráfico de Dispersión (Scatterplot):** Es el primer paso indispensable antes de calcular cualquier métrica, graficando los valores de una variable en el eje X y los de la otra en el eje Y; cada par ordenado se representa mediante un punto. Se implementa mediante `sns.scatterplot()`.
- **Covariancia (SS_{xy}):** Medida estadística que brinda información sobre el grado en que dos variables varían linealmente en forma conjunta:

$$SS_{xy} = \frac{1}{n-1} \sum_{i=1}^n (X_i - \overline{X})(Y_i - \overline{Y})$$

- **Interpretación del signo:** Provee información sobre la dirección de la asociación lineal. Si la relación es directa o positiva, $SS_{xy} > 0$; si es inversa o negativa, $SS_{xy} < 0$. Para dos variables estadísticamente independientes, $SS_{xy} = 0$, pero lo opuesto no es necesariamente cierto (pueden tener covariancia cero y presentar una fuerte asociación no lineal). Método Pandas: `cov()`.
- **Limitaciones:** **No tiene un rango de variación acotado** (su magnitud no indica la fuerza de la asociación) y **es altamente sensible a las unidades de medida**, haciéndose arbitrariamente grande o pequeña si se modifican las escalas.
- **Coeficiente de Correlación de Pearson (r):** Mide el **grado de asociación lineal que existe entre dos variables cuantitativas continuas**:

$$r = \frac{S_{xy}}{S_x S_y}$$

Método Pandas: `corr(method='pearson')`.

- **Propiedades:** Su signo indica la dirección y está estrictamente acotado entre **-1 y 1**. Su magnitud denota la fuerza de la asociación lineal (cercano a 0 es débil; cercano a 1 o -1 es una relación fuerte). Si las variables son independientes, $r = 0$, pero $r = 0$ no implica falta de asociación, sino falta de linealidad.
- **Guía práctica de interpretación (Criterio arbitrario):** $|r| < 0.5$ (relación lineal débil); $0.5 \leq |r| < 0.8$ (relación lineal moderada); $|r| \geq 0.8$ (relación lineal intensa).
- **Problemas de Interpretación:**
 1. **Correlación no implica causalidad:** Que dos variables estén fuertemente correlacionadas no significa que una sea la causa de la otra.
 2. **Exige linealidad de forma estricta:** Si la relación no es lineal, calcular e informar r es inapropiado. Es obligatorio graficar los datos previamente.
 3. **Es altamente sensible a outliers:** Los valores atípicos pueden distorsionar enormemente su valor conduciendo a conclusiones equivocadas.
- **Coeficiente de Correlación de Spearman (r_s):** Mide la fuerza y dirección de relaciones monótonas (cuando al aumentar una variable la otra tiende siempre a aumentar o siempre a disminuir, de forma constante pero no necesariamente en línea recta). Se calcula **rankeando los datos ordenados de ambas variables y computando el coeficiente de Pearson directamente sobre esos rangos asignados**:

$$r_s = \frac{S_{(R_x R_y)}}{S_{(R_x)} S_{(R_y)}}$$

- **Aplicaciones:** Es idóneo al trabajar con **datos ordinales**, cuando la relación entre variables es **monótona pero no lineal**, o cuando existen **outliers** que distorsionan el coeficiente de Pearson (ya que al basarse en rangos es mucho menos sensible a extremos). Toma valores entre -1 y 1. Método Pandas: `corr(method='spearman')`.
- **Matrices de Resumen:** Permiten construir estructuras matriciales de correlación o covariancia para todas las combinaciones posibles cuando se cuenta con múltiples variables cuantitativas. Un **Correlograma** es la representación gráfica de una matriz de correlación mediante un mapa de calor (`sns.heatmap()`).

UNIDAD 4: VISUALIZACIÓN DE DATOS

1. Fundamentos de la Visualización

- **¿Por qué visualizar?:** El cálculo de estadísticas no permite contar la historia completa (ej. **Datasaurus Dozen**, donde conjuntos con idénticas medias, desviaciones estándar y correlación exhiben formas totalmente dispares al graficarse). Representar la información visualmente facilita la detección de tendencias, patrones, outliers y correlaciones, cumpliendo un rol central en la generación de conocimiento y comunicación de resultados.
- **Librerías principales en Python:**
 - **Matplotlib:** Biblioteca base de visualización en Python; su módulo más utilizado es `pyplot`.
 - **Seaborn:** Librería de gráficos de alto nivel construida sobre matplotlib que simplifica la creación de visualizaciones comunes de uso frecuente.
 - **Plotnine:** Implementación en Python de la **Grammar of Graphics (Leland Wilkinson, 1999)** basada en el paquete `ggplot2` de R, que provee un sistema estructurado para combinar elementos gráficos significativos.
 - **Clasificación de Claus Wilke:** Propone clasificar las herramientas según el objetivo perseguido: visualizar cantidades y proporciones, visualizar distribuciones, visualizar relaciones entre dos variables cuantitativas o representar datos geoespaciales.

2. Gráficos para Visualizar Distribuciones

- **Distribución:** Se refiere a cómo se reparten los valores de una variable: qué valores aparecen, con qué frecuencia y en qué rangos se concentran.

- **Gráfico de Bastones:** Adecuado para **variables cuantitativas discretas** cuando el número de observaciones es grande pero existen pocos valores únicos diferentes. En el eje X se representan los valores observados de la variable y en el de ordenadas las correspondientes frecuencias (absolutas o relativas), levantando un segmento vertical de altura igual a su frecuencia. En Seaborn se genera con `countplot()`, seteando el parámetro `width` en un valor pequeño y configurando el eje Y mediante el parámetro `stat` (`count` por default, `percent` o `proportion`).
- **Histograma de Frecuencias:** Utilizado para representar datos de una **variable cuantitativa que asume un gran número de valores diferentes** (continuas). Agrupa los valores de la variable en intervalos contiguos (**bins**) en el eje de abscisas y levanta rectángulos cuyas áreas representan la frecuencia absoluta o relativa del subintervalo en el eje de ordenadas. Se implementa mediante la función `histplot()`.
- ***Efecto del parámetro bins*:** Configura el número de subintervalos; puede definirse por reglas de referencia (ej. `bins='sqrt'`, la raíz cuadrada de $\$n$), por un número entero fijo (ej. `bins=10`), o mediante una lista con los breaks exactos (ej. `bins=[0, 5, 10]`). Parámetros asociados: `binwidth` (amplitud del intervalo) y `binrange` (rango cubierto).
- **Gráfico de Densidad (Density Plot):** Intenta visualizar la distribución de probabilidad subyacente mediante el dibujo de una curva continua estimada a partir de los datos mediante la **Estimación de Densidad por Kernel (KDE)**.
- **Funcionamiento:** "Dibuja" una curva suave llamada kernel (generalmente gaussiano) con un ancho determinado (**bandwidth**) en la ubicación de cada punto, sumando todas las curvas individuales para obtener la estimación de densidad global. Se implementa con `kdeplot(fill=True)`.
- **La trampa de la densidad:** Las estimaciones por kernel tienden a producir la apariencia de que existen datos en las colas donde matemáticamente no existen (ej. valores de edad negativos). Se soluciona configurando el parámetro `clip=[mín, máx]` para truncar el gráfico en puntos específicos lógicos del eje. Se pueden ajustar los límites visuales con `plt.xlim()`.
- **Escala del eje:** Las curvas se escalan de manera que el área bajo la curva sea igual a uno, lo que puede volver confuso el eje y ya que depende de las unidades del eje x.
- ***Parámetro bw_method*:** Modifica el ancho de banda (ej. `'scott'` por defecto o valores específicos numéricos). Anchos de banda muy pequeños producen curvas rugosas sobreajustadas; anchos de banda muy grandes suavizan en exceso perdiendo la forma de la distribución.
- **Superposición:** Seteando el parámetro `kde=True` dentro de `histplot()` se superpone la curva de densidad al histograma.

3. Comparar Distribuciones entre Múltiples Grupos

- Se aplica cuando el interés radica en comparar cómo se distribuye una variable cuantitativa en distintos grupos definidos por una variable categórica.
- **Gráficos de Densidad Múltiples:** Representa la distribución segmentada configurando en `kdeplot()` los parámetros `hue='variable_categórica'` y `multiple='layer'` (para superponer curvas).
- **Boxplot Múltiple:** Permite visualizar de forma paralela diagramas de caja para cada grupo usando `boxplot(hue='variable_categórica')`. Resume centralidad y outliers, pero pierde información sobre detalles finos de la forma de la distribución (como la presencia de múltiples picos o modas) en comparación con las curvas de densidad.
- **Strip Plots / Jitter Plots:** Representan directamente todos los datos individuales en la forma de puntos. Cuando hay muchos datos, para evitar graficar puntos uno encima del otro (*overplotting*), se dispersan añadiendo algo de ruido aleatorio en la dimensión visual, técnica llamada **jittering**. Se construye con `stripplot()` seteando el grado de dispersión en el parámetro `jitter`.
- **Violin Plot:** Gráfico que representa una **estimación de densidad por Kernel mostrada de forma espejada**, generando una figura simétrica cuyo ancho en cada valor es proporcional a la densidad de observaciones. Presenta la limitación de requerir un número suficiente de observaciones por grupo para evitar estimaciones inestables o picos falsos. Incorpora por defecto un boxplot interno con la mediana y el rango intercuartil (se puede ocultar con `inner=None` o modificarse en `inner_kws` e introducir cambios en el grosor con `gap`).
- **Sina Plot:** Combinación avanzada que consiste en **superponer un strip plot directamente sobre un violin plot**.
- **Ridgeline Plot:** Representa múltiples curvas de densidad por kernel **desplazadas verticalmente de forma escalonada**, creando un efecto visual de "cadena montañosa". Es especialmente útil para comparar la forma y posición de las distribuciones entre muchos grupos (categorías nominales o con orden natural) o rastrear cambios distribucionales a lo largo del tiempo cronológico. Posee limitaciones de interpretación cuando hay un solapamiento excesivo, pocas observaciones o un número muy elevado de grupos.

4. Gráficos para Conteos y Proporciones

- Se aplican cuando la variable de interés es **cualitativa o categórica**, cambiando el objetivo a comparar frecuencias o proporciones entre categorías.
- **Gráfico de Barras:** Grafica una barra (generalmente horizontal) para cada categoría. El ancho es idéntico para todas, pero **su longitud es estrictamente proporcional al porcentaje o conteo de unidades** pertenecientes a dicha categoría. Se implementa mediante la función `countplot(y='variable', stat='percent')`.
- **Barras Agrupadas o Paralelas:** Se utiliza para visualizar **ambas variables categóricas de forma simultánea**. Representa un grupo de barras en cada posición a lo largo del eje, asociando cada barra a un nivel de la segunda variable categórica mediante el parámetro `hue`.
- **Tabla de Contingencia:** Resumen en forma de matriz de doble entrada que se genera en Pandas con la función `crosstab()`. Su parámetro `normalize` define el cálculo de proporciones: `'all'` (sobre el total de datos), `'index'` (por filas) o `'columns'` (por columnas).
- **Gráfico de Barras Apiladas (Stacked Bars):** Parte de la tabla de contingencia y muestra las barras superpuestas de forma secuencial, implementándose con el método `.plot.barh(stacked=True)` de Pandas.
- **Distribución Conjunta vs. Distribución Condicional:**
- **Distribución Conjunta:** Los porcentajes de las categorías están calculados sobre el **total absoluto de las observaciones del dataset** (la suma de todas las barras de la visualización da 100%). Su título representativo es "Distribución de pasajeros según clase y supervivencia".

- **Distribución Condicional:** Los porcentajes se calculan y **suman el 100% dentro de cada nivel o categoría específica** de una variable (frecuencia de supervivencia dada la clase). Su título representativo es "Supervivencia de los pasajeros según la clase en la que viajaban".
- **Gráfico de Sectores (Pie Chart):** Divide un círculo (100%) en sectores donde el área de cada uno es proporcional al porcentaje de la categoría, implementándose con `plt.pie()` de matplotlib. *Desventaja analítica:* Cuando el conjunto posee un gran número de categorías o proporciones muy similares, **el gráfico de sectores se vuelve engorroso y confuso**, siendo preferible utilizar siempre un gráfico de barras.

5. Visualización de Datos Geoespaciales

- **Geodesia:** Ciencia que estudia la forma y dimensiones de la Tierra para poder ubicar puntos o regiones georreferenciadas de forma exacta sobre su superficie. Modelos de la superficie terrestre:
 1. **Esfera:** Modelo matemático simplificado con ecuaciones conocidas que facilitan cálculos de distancia, pero es imperfecto ya que la Tierra no es una esfera perfecta.
 2. **Elipsoide:** Forma geométrica tridimensional creada a partir de la rotación de una elipse que se adapta mejor a la realidad. La rotación terrestre deforma al planeta haciendo que sea más alargado en el Ecuador (semieje mayor) y achatada en los polos (semieje menor), por lo que el radio no es constante. Existen elipsoides **locales** (ajustados a una zona específica) y **globales o generales** (coinciden el centro de gravedad y el plano ecuatorial con los terrestres). El elipsoide de referencia global estándar actual es el **WGS 84** (superficie base del sistema GPS).
 3. **Geoide:** Modelo irregular con protuberancias y depresiones que reproduce la forma real de la Tierra atendiendo a que su masa no es uniforme en todos los puntos, cambiando localmente la fuerza gravitatoria y la dirección de la gravedad.
- **Datum Geodésico:** Sistema de referencia que proporciona un modelo para medir ubicaciones sobre la superficie de la Tierra en relación con un elipsoide particular ajustado apropiadamente a una región y momento determinado (época). Se clasifican en globales o geocéntricos (ej. datum global WGS 84 usado en GPS) y locales (diseñados para una región en particular alineando estrechamente su esferoide, ej. Campo Inchauspe, Chos Malal y Tapi Aike en Argentina). Un datum local no es adecuado fuera de su zona específica de diseño.
- **Sistema de Coordenadas de Referencia (CRS):** Fundamental para conocer las unidades de trabajo y realizar operaciones espaciales válidas entre datasets (no se pueden unir si tienen diferentes CRS).
- **Coordenadas Geográficas:** Sistema esférico que localiza un punto mediante dos valores angulares: **latitud (\$\phi\$)** y **longitud (\$\lambda\$)** tomando como referencia el Ecuador (paralelos) y los meridianos.
- **Proyecciones Cartográficas:** Proceso matemático biunívoco de asignar una coordenada plana cartesiana (X e Y) sobre una superficie plana a cada punto de la superficie esférica o elipsoidal. Superficies habituales: **Plana o Azimutal** (proyecta sobre un plano tangente a la esfera en un punto seleccionado), **Cónica** (desarrolla un cono tangente o secante en dos paralelos, útil para franjas que no abarquen gran distancia en latitud, ej. Albers y Lambert) y **Cilíndrica** (apariencia de rectángulo desenrollado donde meridianos y paralelos son líneas paralelas, ej. Mercator y Lambert).
- **GeoPandas:** Librería de Python de código abierto que proporciona soporte para datos georreferenciados basándose en objetos Pandas. Almacena la información de las geometrías en una columna especial llamada **geometry**. Lee archivos geoespaciales (Shapefiles, GeoJSON o GML—Lenguaje de Marcado Geográfico basado en XML) mediante la función `gpd.read_file()`, convirtiéndolos en un objeto **GeoDataFrame**. Geometrías de objetos geográficos comunes:
 1. **POINT (Punto):** Ubicación individual definida por una coordenada de latitud y longitud (ej. efector de salud, sensores).
 2. **LINESTRING (Línea):** Secuencia de puntos conectados que forman objetos lineales (calles, ríos, rutas).
 3. **POLYGON (Polígono):** Área cerrada formada por una secuencia de puntos que representa una superficie geográfica (barrios, parcelas, lagos).
 4. **MULTIPOLYGON:** Agrupa múltiples polígonos relacionados entre sí que no necesariamente son contiguos (un archipiélago de islas, departamentos de una provincia).
- **Representación Visual:** El método `.plot()` sobre un GeoDataFrame dibuja el mapa, admitiendo argumentos como `edgecolor`, `linewidth`, `column` (para colorear según variable) y `legend=True` configurando leyendas con `legend_kwds`. El método `.boundary.plot()` dibuja exclusivamente los límites perimetrales sin relleno.
- **Reproyección:** Si al consultar con el método `.crs` se detecta un CRS Proyectado cuyas coordenadas están en metros (ej. POSGAR 98 / Argentina 4, EPSG:22174), se debe reproyectar a un CRS geográfico en grados (como EPSG:4326 / WGS 84) mediante el método `.to_crs(epsg=4326)` para representar las coordenadas adecuadamente.
- **Librería Folium:** Biblioteca de Python basada en Leaflet.js diseñada para crear mapas interactivos dinámicos visualizables en navegadores web, permitiendo personalizaciones con capas y marcadores. Permite construir **Mapas Cloropleth**, representaciones gráficas donde las áreas geográficas están coloreadas o sombreadas en función de la intensidad o el valor numérico de un atributo cuantitativo específico (ej. superficie cultivada o tasa de población).

UNIDAD 6: REGRESIÓN LINEAL

1. Concepto de Modelo Estadístico

- **Modelo:** Representación simplificada y abstracta de la realidad que constituye una herramienta útil para responder interrogantes y resolver problemas.
- **Modelo Base (Una variable):** Ante la disponibilidad única de las observaciones de una variable respuesta continua Y (sin otras variables predictoras), el modelo predictivo elemental está dado por el promedio o **media aritmética** de la muestra, expresándose matemáticamente como:

$$\hat{y} = \overline{y}$$

Representa un valor constante a través de todos los registros.

- **Análisis de Regresión:** Conjunto de herramientas estadísticas y matemáticas que permiten explicar (modelar) el comportamiento de una **variable respuesta** o

dependiente (\$Y\$) a partir de la información proporcionada por una o más variables explicativas, predictoras o independientes (\$X_1, X_2, \dots, X_p\$).

2. El Modelo de Regresión Lineal Simple

- La relación general entre \$Y\$ y los predictores se escribe como:

$$Y = f(X) + \epsilon$$

Donde \$f(X)\$ es una función fija pero desconocida que captura la relación sistemática entre las variables, y \$\epsilon\$ es el **término de error aleatorio** que recoge todo lo no incluido en el modelo (variables omitidas, variaciones no medibles, ruido).

- Cuando es razonable suponer que \$f(X)\$ describe una línea recta, el modelo toma la forma del **Modelo de Regresión Lineal Simple**:

$$Y = \beta_0 + \beta_1 X + \epsilon$$

- Parámetros o Coeficientes Poblacionales:**
- \$\beta_0\$ (Ordenada al origen o Intercept):** Valor promedio esperado de la variable respuesta \$Y\$ cuando la variable explicativa \$X\$ es igual a cero.
- \$\beta_1\$ (Pendiente o Slope):** Cambio promedio esperado en la variable respuesta \$Y\$ cuando la explicativa se incrementa en una unidad.
- Influencia de \$\epsilon\$:** Debido a la inclusión del error aleatorio, dado un valor específico del predictor \$x_i\$, no se puede especificar de forma exacta el valor individual de la respuesta.
- Función de Regresión:** Representa a la ecuación de la recta teórica desconocida del valor esperado condicional, especificada desde el punto de vista estadístico como:

$$f(X) = E[Y|X] = \mu_{Y|X} = \beta_0 + \beta_1 X$$

3. Estimación por Mínimos Cuadrados Ordinarios (OLS)

- A partir de una muestra de \$n\$ pares observados \$(x_i, y_i)\$, se estima la función (recta) de regresión calculando los estimadores puntuales de los parámetros poblacionales:

$$\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x$$

- Residuos (\$e_i\$):** Representan las distancias verticales exactas desde los puntos reales observados hasta la recta estimada por el modelo. Actúan como errores del ajuste muestral y se calculan mediante:

$$e_i = y_i - \hat{y}_i = y_i - (\hat{\beta}_0 + \hat{\beta}_1 x_i)$$

- Método de Mínimos Cuadrados (OLS):** Provee las estimaciones de la recta que mejor ajusta a los datos experimentales encontrando estrictamente los valores de \$\hat{\beta}_0\$ y \$\hat{\beta}_1\$ que **minimicen la suma de los residuos al cuadrado (Suma de Cuadrados del Error, \$SSC_{\text{Error}}\$ o RSS)**:

$$\sum_{i=1}^n e_i^2 = \sum_{i=1}^n (y_i - \hat{y}_i)^2 = \sum_{i=1}^n (y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i)^2 = \text{Mínimo}$$

- Ecuaciones Normales:** Se obtienen derivando parcialmente la sumatoria con respecto a \$\hat{\beta}_0\$ y \$\hat{\beta}_1\$, igualando ambas derivadas parciales a cero y resolviendo el sistema resultante, de lo cual derivan las fórmulas de solución cerrada:

$$\hat{\beta}_1 = \frac{\sum_{i=1}^n x_i y_i - n \overline{x} \overline{y}}{\sum_{i=1}^n x_i^2 - n \overline{x}^2}$$

$$\hat{\beta}_0 = \overline{y} - \hat{\beta}_1 \overline{x}$$

- En Python, se utiliza el módulo **statsmodels** para realizar de forma directa el ajuste del modelo OLS, la estimación y el análisis estadístico de las salidas.

4. Evaluación de la Calidad del Ajuste

- La variabilidad observada en las respuestas se divide en explicada por el modelo (porque las propiedades tienen distintos predictores) y no explicada (por causas aleatorias y variables omitidas).
- Coefficiente de Determinación (\$R^2\$):** Mide la proporción de la variabilidad total en las observaciones de la variable respuesta \$Y\$ que es explicada satisfactoriamente por el modelo.
- Su rango de variación numérica está acotado entre **0 y 1**. Si el ajuste es perfecto, \$R^2 = 1\$ (el modelo captura el 100% de la variabilidad). Si el modelo no explica nada, \$R^2 = 0\$. Cuanto más cercano a 1 sea su valor, mayor será la capacidad explicativa del modelo.
- Importante:** Un \$R^2\$ alto **no garantiza bajo ningún concepto que el modelo sea adecuado**. Puede ser elevado incluso cuando la relación real no es lineal, ante valores atípicos influyentes o cuando el modelo sobreajusta los datos. Debe acompañarse siempre de exploración gráfica y análisis de residuos.
- Error Cuadrático Medio (MSE):** Evalúa qué tan próximos se encuentran los valores predichos de los observados empleando la media de los residuos al cuadrado:

$$\text{MSE} = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2 = \frac{SSC_{\text{Error}}}{n}$$

Al elevar al cuadrado las distancias, **esta métrica penaliza fuertemente a los errores grandes y valores atípicos**.

- Raíz del Error Cuadrático Medio (RMSE):** Es la raíz cuadrada positiva del MSE (\$\text{RMSE} = \sqrt{\text{MSE}}\$). Resuelve el problema de interpretación del MSE al quedar **expresada en las mismas unidades originales de la variable respuesta \$Y\$**, siendo la métrica más utilizada en la práctica para reportar el error típico de predicción de un modelo.
- Error Absoluto Medio (MAE):** Calcula el promedio de tomar los valores absolutos de los residuos:

$$\text{MAE} = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i|$$

Al no elevar al cuadrado, es una métrica inherentemente robusta a distorsiones causadas por la presencia de valores atípicos, prefiriéndose cuando el contexto no justifica penalizar más a los errores grandes.

5. Regresión Lineal Múltiple y Variables Dummy

- **Regresión Lineal Múltiple:** Extensión útil que permite incorporar **múltiples variables explicativas o predictoras** ($X_1, X_2, \dots, X_p$) simultáneamente para predecir la respuesta:

$$Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \beta_3 X_3 + \dots + \beta_p X_p + \epsilon$$

- **Incorporar una Variable Cualitativa:** Para introducir un predictor cualitativo o categórico de dos niveles se crea una **variable dummy numérica** que adopta los valores lógicos:

$$X_2 = \begin{cases} 1, & \text{si cumple la condición del nivel} \\ 0, & \text{si no la cumple} \end{cases}$$

Su inclusión genera rectas de regresión paralelas para cada nivel categórico, asumiendo de forma estándar que la influencia del predictor continuo es idéntica independientemente del grupo cualitativo (la diferencia en la respuesta es un término aditivo representado de forma fija por el coeficiente β_2).

- **El problema del R^2 y la solución del R^2 Ajustado (R^2_{adj}):** Dado que incorporar nuevos predictores al modelo siempre reduce o mantiene igual el error de ajuste, el R^2 tradicional **nunca disminuye al agregar variables**, aunque estas no aporten información real, volviéndolo una métrica poco útil para comparar modelos con distinto número de predictores.

- El **R^2 Ajustado (R^2_{adj})** corrige este problema penalizando estrictamente la complejidad o número de variables del modelo:

$$R^2_{\text{adj}} = 1 - \frac{SC_{\text{Error}}}{(n - p - 1)S_Y^2}$$

A diferencia del R^2 , el R^2_{adj} **puede disminuir si se agrega una variable que no mejora el ajuste de forma genuina**, consolidándose como la métrica adecuada para comparar modelos con distinta cantidad de predictores.

6. Inferencia, Predicción y Contraste de Hipótesis

- **¿Por qué interesa estimar β ?**
- **Para hacer Predicciones:** La respuesta Y no puede obtenerse fácilmente pero los predictores están disponibles. Bajo esta concepción, β se trata metodológicamente como una **caja negra** enfocado exclusivamente en la exactitud de las predicciones de $\hat{y}$ (sin interés en la forma matemática exacta).
- **Para hacer Inferencias:** Interesa conocer explícitamente **la forma matemática en que los predictores influyen sobre la respuesta** (cuáles están asociados, cuáles son los más importantes, la dirección de su relación y si puede resumirse mediante una ecuación lineal o requiere formas complicadas).
- **Ensayar Hipótesis sobre los Coeficientes (Selección de Variables):** Procedimientos estadísticos empleados para tomar una decisión acerca del valor de parámetros poblacionales en base a la información de una muestra, evaluando si las variables independientes están realmente relacionadas con la respuesta o si se puede prescindir de ellas. Para un coeficiente específico se testea:
 - **Hipótesis Nula (H_0):** $\beta_1 = 0$ (No hay relación lineal entre el predictor e Y ; se puede prescindir de él).
 - **Hipótesis Alternativa (H_1):** $\beta_1 \neq 0$ (Hay relación lineal significativa entre el predictor e Y).
- **Enfoque de la Probabilidad Asociada (p-value):** Medida de cuánta evidencia se tiene, en el marco del modelo y los datos muestrales, a favor de sostener como cierta la hipótesis nula. Por lo tanto, valores pequeños de p-value llevan a pensar que el predictor está relacionado con la respuesta. En la práctica, se considera de forma estándar que **valores de p-value < 0.05 son suficientes para rechazar la hipótesis nula por falsa**, declarando estadísticamente la relevancia del predictor. Entre modelos con distinta cantidad de variables se selecciona el que maximiza el R^2_{adj} .

7. Calidad Predictiva y Sobreajuste (Overfitting)

- El **MSE de entrenamiento (training MSE)** se calcula estrictamente utilizando los mismos datos empleados para ajustar el modelo. Al aumentar la complejidad o flexibilidad del modelo, el training MSE **disminuye de forma continua** porque las ecuaciones se ajustan cada vez más a las particularidades exactas de la muestra.
- Analíticamente interesa la calidad de las predicciones sobre datos independientes que el modelo nunca vio (**datos de testeo**), requiriendo un **test MSE**. Conforme aumenta la complejidad del modelo, el test MSE describe una **curva en forma de U**: disminuye inicialmente al capturar la estructura real de los datos, alcanza un valor mínimo en una flexibilidad intermedia y luego vuelve a aumentar notablemente conforme el modelo gana complejidad y pierde capacidad de generalización.
- **Sobreajuste (Overfitting):** Fenómeno que ocurre cuando un modelo ajustado proporciona un training MSE muy pequeño junto con un gran test MSE. Ocurre porque el algoritmo de aprendizaje estadístico está sumamente enfocado en encontrar patrones y memorizar estructuras ruidosas en los datos de entrenamiento que en realidad son provocados exclusivamente por fluctuaciones aleatorias, provocando que el error de testeo crezca debido a que esos supuestos patrones simplemente no existen en la realidad ni en los datos de testeo.

8. Redflags (Incumplimientos de Supuestos) en Regresión

Representan alertas estructurales críticas observadas en el diagnóstico del modelo que desestiman la validez de las conclusiones de un ajuste lineal ordinario si no se corrigen:

1. **No linealidad de la relación Respuesta-Predictor.** El modelo asume que existe una relación lineal recta entre variables. Si la relación verdadera está lejos de ser lineal, todas las conclusiones y tests son dudosos. Se identifica mediante un **Gráfico de Residuos (e_i) vs. Valores Predichos ($\hat{y}_i$)**; si el gráfico sugiere patrones curvos u organizados en lugar de una nube difusa aleatoria, el supuesto se rompe. *Solución:* Utilizar transformaciones no lineales de los predictores en la ecuación, como $\log(X)$, $\sqrt{X}$ o X^2 .
 2. **Falta de Normalidad:** Importante supuesto que exige que los errores tengan una distribución normal. Los incumplimientos de esta asunción se evalúan gráficamente representando la distribución de los residuos (histogramas o gráficos de densidad) o, de forma más precisa, realizando un **Normal Q-Q Plot de residuos**, donde los puntos deben alinearse de forma exacta sobre la recta de referencia esperada.
 3. **Heterocedasticidad:** Supuesto clásico que exige que los errores del modelo tengan una variancia o variabilidad constante a lo largo de las observaciones. Se detecta analíticamente ante la **observación de patrones tipo embudo** en el gráfico de residuos vs. fitted values. *Solución:* Realizar transformaciones sobre la variable respuesta Y empleando una función cóncava, como $\log(Y)$ o $\sqrt{Y}$.
 4. **Presencia de Outliers:** Puntos para los que el valor real observado y_i se encuentra atípicamente alejado del valor predicho por el modelo. Aunque a veces no causan grandes problemas directos en las estimaciones de los coeficientes, **influyen drásticamente sobre las medidas de inferencia estadística porque pesan mucho sobre la suma de cuadrados del error (SSC_{Error})**, distorsionando variancias y tests.
 5. **Colinealidad y Multicolinealidad:** Se presenta cuando dos o más variables predictoras incorporadas están íntimamente asociadas o correlacionadas entre sí. Esto provoca que sea sumamente difícil o imposible separar, aislar y evaluar satisfactoriamente los efectos individuales específicos de cada predictor sobre la variable respuesta Y . Se detecta analizando la matriz de correlación de los predictores.
- *Herramientas en Python.* Gráficos de diagnóstico implementados mediante Seaborn `sns.regplot(lowess=True)` (agrega una línea suavizada para seguir la forma general de los residuos) y `statsmodels` usando `sm.qqplot(line='s')` para la recta teórica normal esperada.
-

9. Enfoques Algorítmicos para Obtener Coeficientes

- **Solución Cerrada (Analítica):** Expresiones matemáticas e ingeniería de fórmulas directas deducidas algebraicamente a partir de aplicar el Método de Mínimos Cuadrados Ordinarios (OLS), computando las estimaciones exactas en un único bloque operativo.
- **Algoritmo de Optimización Iterativo (Descenso de Gradiente):** Enfoque iterativo dinámico ampliamente utilizado en el entrenamiento de modelos de Machine Learning y Redes Neuronales. Consiste en inicializar los coeficientes con valores aleatorios e **ir ajustándolos progresivamente dando pasos sucesivos en la dirección de máximo descenso (gradiente negativo) de una función de pérdida o de costo convexa predefinida (como el MSE en regresión)**, guiando de manera iterativa al modelo hacia la solución óptima global de mínimos errores.