

¿Qué son los DATOS?

Los datos son piezas de información de un tema en particular y pueden presentarse en tres formatos principales:

- **Datos Estructurados:** Poseen un formato estandarizado en forma tabular (**filas y columnas**). Sus atributos son definibles y relacionales (permiten vincular tablas). Idealmente se almacenan en **bases de datos relacionales con lenguajes como SQL**.
- **Datos No Estructurados:** No poseen modelo predefinido ni esquema fijo. Incluyen **correos electrónicos, chats, imágenes, audio y video**. Representan más del **80% de los datos** mundiales y son difíciles de organizar, buscar y analizar con herramientas tradicionales.
- **Datos Semi-estructurados:** Categoría intermedia que utiliza etiquetas (*tags*) o pares clave-valor. Ejemplos típicos son **XML, JSON y YAML**.
 - **XML:** Lenguaje de marcado con etiquetas anidadas y atributos.
 - **JSON:** Basado en JavaScript, usa llaves {} para jerarquías.
 - **YAML:** Elimina caracteres especiales y utiliza la **indentación** de líneas.

Datos Tabulares y Formatos de Almacenamiento

Para almacenar datos en forma tabular, se usan comúnmente archivos **.csv, .json, .txt, .html y .parquet**. Pueden orientarse de dos formas:

- **Orientados a filas:** Los datos de un registro se guardan juntos en la memoria (ej. bases de datos tradicionales). Son ineficientes si se consulta solo un atributo.
- **Orientados a columnas:** Guardan los datos de una misma variable juntos. Permiten leer columnas individuales rápido y logran **mejor compresión**.
- *Características de los formatos:*
 - **CSV:** Valores separados por comas, tabuladores o punto y coma. **No guardan información sobre el tipo de dato**.
 - **TXT:** Símil al CSV, simple y amplio en su uso.
 - **Parquet:** Formato **orientado a columnas**, altamente comprimido y eficiente, usado fuertemente en *Big Data* (Hadoop, Spark).
 - **HTML:** Basado en etiquetas de marcado (<table>, <tr> para filas, <th> para encabezados, <td> para celdas).

Repaso de PANDAS

Librería de Python eficiente para organizar y analizar estructuras de datos. Sus estructuras básicas son:

- **Series:** Matriz **unidimensional** para un solo tipo de dato, identificada por un **índice**.

- **DataFrame:** Estructura **bidimensional tabular** (filas y columnas) donde cada columna puede tener distinto tipo de dato.

Tipos de datos usuales: `int` (enteros), `float` (decimales), `str` o `object` (texto/cadenas de caracteres), `bool` (`True/False`) y `NaN/None` (valores faltantes). **Lectura de archivos:** Funciones como `read_csv()`, `read_excel()`, `read_json()`, `read_parquet()` los convierten en DataFrames. **Métodos útiles:**

- `.rename()`: Renombra columnas o índices.
- `.str.replace()` y `.str.strip()`: Útiles para modificar texto o quitar espacios blancos.
- `.str.lower()` / `.str.upper()`: Textos a minúsculas o mayúsculas.
- `.astype(tipo)`: Convierte el tipo de dato.
- `.isnull()` / `.isna()` / `.notnull()`: Detectan booleanos en valores faltantes.
- `.unique()` y `.value_counts()`: Devuelven valores únicos y sus frecuencias.

Manejo de Fechas

El módulo **datetime** manipula fechas y horas. Posee objetos **naive** (sin información de huso horario) y **aware** (con información explícita de zona horaria mediante librerías como `pytz`).

- **Conversión con `pd.to_datetime()`:** Convierte texto a objetos temporales. Permite usar parámetros como `dayfirst=True` o `format` (ej. `%d/%m/%Y`) para especificar estructuras.
- **Sobre `datetime64`:** Tipo de dato numérico interno (**64 bits**) que representa una fecha como un entero evaluando la diferencia temporal en relación a la base del **1 de enero de 1970** (con precisión hasta nanosegundos [ns]).

Data Wrangling

Es el proceso de **preparar y formatear los datos** para permitir su análisis posterior.

De Formato Ancho a Formato Largo... (y viceversa)

Reformar DataFrames es común en Pandas.

- **`pd.melt()`:** Operación que junta múltiples columnas en una sola para transponer los datos a formato largo. Requiere definir las variables identificadoras (`id_vars`) y las variables de valores (`value_vars`).

Manejo de Datos Faltantes

La aparición de huecos (**los famosos NaN**) es usual y puede alterar drásticamente análisis y conclusiones si no se trata correctamente. Opciones de acción:

- **Eliminar registros (`dropna()`):** Borra filas enteras (o columnas agregando `axis='columns'`). `how='all'` restringe que se borren solo los que tienen **todos** sus valores como NaN. ¡Atención!: Implica pérdida grave de información relevante de forma aleatoria.
- **Imputar valores (`fillna()`):** Llena los huecos con valores potenciales. Estrategias:

- **Medidas representativas:** Usar media, mediana, moda general o de forma **segmentada/agrupada** (por ejemplo, el precio promedio dependiendo del barrio).
- **Valor aleatorio:** Dentro de los rangos observados.
- **Interpolación:** Uso de valores vecinos para predecir. Puede ser **lineal** (una recta entre dos puntos (x0, y0) y (x1, y1)) o **polinómica** (un polinomio global para los datos).
- **Criterio de Cercanía:** Copiar valores según la distancia espacial o proximidad temporal a registros contiguos.

Combinaciones de Conjuntos de Datos

Pandas ofrece métodos para unir distintos datasets:

- **concat():** Concatena objetos DataFrames a lo largo de un eje específico (vertical u horizontal variando axis). Modificando join='inner' intersecta solo las columnas compartidas.
- **merge():** Operación combinada tipo base de datos relacional que utiliza columnas como llaves (**keys**). Existen diferentes uniones dependientes del parámetro how (**INNER, OUTER, LEFT, RIGHT**). El parámetro on o (left_on/right_on) indica las columnas de cruce.
- **Uniones Cruzadas (Cross Joins):** Se utiliza how='cross' para realizar **todas las combinaciones posibles** de ambas tablas ignorando coincidencias. Precaución: puede generar una matriz excesivamente grande y sin real utilidad analítica.
- **join():** Combina DataFrames a través de **sus índices** (por defecto efectúa un Left Join).

Expresiones Regulares (REGEX)

Proporcionan un lenguaje flexible escrito en caracteres literales y secuencias para **hacer coincidir patrones de búsqueda** (ej. \d para indicar un dígito y {4} como cuantificador).

- **Expresiones en Python (módulo re):**
 - **re.search():** Busca solo la **primera ocurrencia** del patrón.
 - **re.split():** Corta la cadena al encontrar la ocurrencia.
 - **re.findall():** Devuelve **todas las ocurrencias** como una tupla/lista.
 - **re.sub():** Sirve para realizar un **reemplazo**.
- **Expresiones en Pandas (str.extract()):** Utiliza Regex con **grupos de captura definidos con paréntesis ()** para extraer partes de un texto creando una columna nueva. Puede extraer múltiples grupos a la vez hacia distintas columnas. Para extraer varias coincidencias iteradas, se usa **str.extractall()**.

A continuación, presento la información condensada de la **Unidad 3: Medidas de Resumen y Métricas de Correlación**, asegurando que todos los conceptos estén incluidos, manteniendo la estructura de títulos y subtítulos, y resaltando los puntos más importantes.

ANÁLISIS EXPLORATORIO DE DATOS: MEDIDAS DE RESUMEN

VARIABLE Una **variable es una característica o propiedad observada** que puede asumir diferentes valores en una investigación. En un *dataset* en formato largo, cada fila constituye un registro y **cada columna contiene la información de una variable**. Se clasifican en:

- **Cualitativas o categóricas:** Variables que **no son medibles numéricamente**.
 - **Cuantitativas:** Toman valores numéricos. Pueden ser **Continuas** (asumen cualquier valor teóricamente posible dentro de un intervalo) o **Discretas** (solo toman valores aislados).
-

MEDIDAS O ESTADÍSTICAS DE POSICIÓN

Estas medidas brindan información acerca de la **localización del conjunto de observaciones de una variable**.

MEDIA ARITMÉTICA ($\bar{X}$) Es la **suma de los valores observados dividida por el número total de datos**. En Pandas se calcula con el método `.mean()`. El problema es que **depende de todos los valores** registrados, por lo que la presencia de observaciones muy grandes o pequeñas (**outliers**) **influye sensiblemente en ella**.

MEDIANA (Q_2) Es el valor de la variable que **se encuentra en la posición central** del conjunto de datos ordenado. La mitad de las observaciones son menores o iguales que él y la otra mitad son mayores. Es una excelente **alternativa representativa cuando hay outliers**.

MEDIA TRUNCADA (TRIMMED MEAN) Es un promedio donde **se ha eliminado un cierto porcentaje de las observaciones más pequeñas y más grandes** (observaciones extremas) para evitar su efecto desproporcionado. Se usa habitualmente en puntuaciones deportivas.

FRACTILAS O CUANTILOS Son valores de la variable que dividen el **conjunto ordenado de datos en partes que contienen el mismo número de observaciones**.

- **Cuartiles (Q_1, Q_2, Q_3):** Dividen la variable en **4 partes** (25%, 50% que coincide con la mediana, y 75%). En Pandas se calculan con el método `.quantile()`, existiendo diversos métodos de interpolación entre valores adyacentes (lineal, más bajo, más alto, más cercano o punto medio).
- **Decilos:** Dividen las observaciones en **10 partes**.
- **Percentilos:** Dividen las observaciones en **100 partes**.

MODA Es el valor de la variable que **se presenta mayor número de veces** (la de mayor frecuencia). Es la **única medida de posición que puede usarse para datos cualitativos**. A diferencia de otras medidas, un conjunto puede presentar **más de una moda** (bimodal, multimodal).

MEDIDAS O ESTADÍSTICAS DE DISPERSIÓN

Surgen de la necesidad de **describir la variabilidad de los datos**, ya que dos conjuntos pueden tener exactamente la misma media y mediana, pero diferir enormemente en cuánto se alejan sus valores del punto central.

RANGO Es la **diferencia entre el valor mayor y el valor menor** observado ($X_{max} - X_{min}$).

VARIANCIA (S^2) Es una medida de **cuánto se desvían, en promedio, las observaciones respecto a la media aritmética**, expresada al cuadrado.

DESVIACIÓN ESTÁNDAR (S) Se define como la **raíz cuadrada positiva de la variancia**. Tiene la ventaja de estar expresada en **las mismas unidades de la variable original**, por lo que podemos interpretarla como una **"distancia promedio de las observaciones con respecto a la media"**. En Pandas se calcula con el método `.std()`.

COEFICIENTE DE VARIACIÓN (CV) Es el desvío estándar dividido por el valor absoluto de la media aritmética ($S/|\bar{X}|$). Al ser una **medida adimensional** (sin unidades), indica **qué proporción representa el desvío estándar de la media** y se utiliza cuando se desea **comparar la variabilidad de dos o más conjuntos que difieren en unidades o magnitudes**.

RANGO INTERCUARTIL (RI) Es la diferencia entre el tercer y el primer cuartil ($RI = Q_3 - Q_1$). Mide la **dispersión del 50% de los datos centrales**. Su principal ventaja es que **no está influenciada por valores extremos**, por lo que suele utilizarse en acompañamiento a la mediana.

DESVIACIÓN MEDIANA ABSOLUTA (MAD) Es una versión **robusta del desvío estándar** que se basa en la mediana. Se define como **la mediana de los valores absolutos de las diferencias entre cada observación y la mediana general**.

EL MÉTODO `describe()`

Es una función de Pandas que permite **obtener de forma fácil y rápida gran parte de las métricas vistas** para una o varias columnas de un *DataFrame*. Si se aplica a variables **cuantitativas**, brinda el recuento, la media, el desvío estándar, y los 5 números de resumen (mínimo, cuartiles y máximo). Si se aplica a variables **cualitativas**, muestra el recuento, los valores únicos, la categoría más frecuente (top) y su frecuencia.

EL BOXPLOT

Es un gráfico que sirve para construir un **buen resumen de cinco números: los cuartiles (Q_1, Q_2, Q_3), los valores mínimo y máximo**.

EL BOXPLOT MODIFICADO Y LOS OUTLIERS La versión modificada permite **detectar potenciales outliers** u observaciones atípicas.

- Se consideran outliers aquellas observaciones que **caigan estrictamente por fuera del intervalo de Tukey: ($Q_1 - 1.5RI$) a ($Q_3 + 1.5RI$)**.

- La modificación consiste en **extender los bigotes (whiskers) sólo hasta la observación mínima y máxima que NO sean puntos atípicos**. Los outliers se marcan de forma separada como puntos individuales.
- **¿Qué hacemos con los outliers?** Excluir un valor atípico de forma automática puede alterar la distribución original y **sesgar los resultados del análisis**. Solo debe eliminarse si hay evidencia documentada de que corresponde a un error de carga (tipeo), es físicamente imposible, o proviene de una falla en el instrumento de medición.
- Si son valores reales pero atípicos, se recomienda: **analizar los resultados con y sin esa observación**, utilizar **medidas más robustas** (mediana en lugar de media), o utilizar **modelos estadísticos que reduzcan su influencia**.

TABLA DE FRECUENCIAS

Es una forma sencilla de **resumir la información de una variable (usualmente categórica o discreta con poca variedad)**. En Pandas se genera con `.value_counts()`.

- **Frecuencia Absoluta:** Contiene la cantidad de veces que se presentó cada categoría.
- **Frecuencia Relativa:** Es el cociente entre la frecuencia absoluta y el **número total de datos** (proporción).
- **Frecuencias Acumuladas:** Se obtiene al **agregar o sumar la frecuencia relativa de forma acumulada** (método `.cumsum()`) para contabilizar la cantidad de observaciones menores o iguales al límite superior.

Para Variables Continuas: Como tienen un gran número de valores diferentes, es necesario aplicar una **discretización realizando un agrupamiento previo en subintervalos o bins (segmentación)** utilizando el método `pd.cut()` antes de armar la tabla.

MÉTRICAS DE CORRELACIÓN

CORRELACIÓN El análisis de correlación estudia el **comportamiento conjunto de dos variables aleatorias X e Y**; es decir, mide el grado en que ambas variables "cambian" conjuntamente.

GRÁFICO DE DISPERSIÓN (SCATTERPLOT) El primer paso fundamental al estudiar métricas conjuntas es armar este gráfico. Muestra la relación graficando **los valores de una variable cuantitativa en el eje de abscisas y los de la otra en el de ordenadas**, donde cada par forma un punto.

LA COVARIANCIA (S_{xy}) Provee información estadística acerca del grado y la **dirección de la asociación lineal** entre dos variables.

- **Dirección:** Si la relación es directa (positiva) $S_{xy} > 0$. Si es inversa (negativa) $S_{xy} < 0$.
- Si son variables estadísticamente independientes $S_{xy} = 0$, pero que sea cero no asegura independencia, ya que puede existir relación no lineal.

- **Limitaciones:** La covarianza **no tiene un rango acotado de variación** (su magnitud no indica la fuerza) y es **sumamente sensible a las unidades de medida** elegidas.

COEFICIENTE DE CORRELACIÓN DE PEARSON (r) Mide el grado de fuerza de la **asociación lineal** entre variables cuantitativas continuas. Se obtiene estandarizando la covarianza.

- **Propiedades:** Su signo indica si la relación es positiva o negativa. Está estrictamente **acotado entre -1 y 1** ($-1 \leq r \leq 1$).
- **Magnitud:** Cuanto más cercano a 1 o -1, más fuerte; cuanto más cercano a 0, más débil es la relación. Como regla orientativa: $|r| < 0.5$ (débil); $0.5 \leq |r| < 0.8$ (moderada); $|r| \geq 0.8$ (intensa).
- **Problemas de Interpretación y Uso:**
 1. **¡Un alto valor de r no implica causalidad!**
 2. Es válido calcularlo solo cuando **la relación es lineal**. No detecta relaciones cuadráticas, cosenoidales, etc., por lo que es imperativo **graficar previamente** el conjunto de datos.
 3. **Se ve gravemente afectado por la presencia de outliers** (sensible), pudiendo distorsionar completamente la conclusión.

CORRELACIÓN DE SPEARMAN (r_s) Presenta una solución al problema de la sensibilidad de Pearson. Se calcula **rankeando (ordenando y asignando un rango) los datos originales** y luego aplicando la fórmula de correlación lineal clásica.

- **Propiedades:** Toma valores entre -1 y 1. Es una alternativa basada en rangos, lo que la hace **menos sensible (más robusta) a los outliers**.
- Especialmente útil en tres escenarios: permite usar **datos ordinales**, puede identificar **cualquier relación que sea monótona (aún si no es lineal)**, y maneja eficientemente valores extremos.

MATRIZ DE COVARIANCIA / CORRELACIÓN Cuando tenemos múltiples variables cuantitativas, podemos construir una matriz que muestre cruzadas las métricas conjuntas de todos los pares. Se genera utilizando los métodos de Pandas `.cov()` o `.corr()`.

CORRELOGRAMA Es una **representación gráfica matricial de las correlaciones** generada mediante el ploteo de un **mapa de calor (heatmap)**. Permite revisar velozmente la escala de colores o intensidades de las correlaciones presentes para comprender la interacción general de las variables.

Aquí tienes el resumen condensado de la Unidad 4 completa, manteniendo la estructura de títulos y resaltando los conceptos más importantes:

ANÁLISIS EXPLORATORIO DE DATOS: Visualizaciones (UNIDAD 4 - Parte 1)

¿Por qué visualizar? La visualización es una forma de **representar información visualmente para generar conocimiento**, lo que facilita la detección de **tendencias, patrones, valores atípicos y correlaciones**.

Herramientas de visualización en Python

- **Matplotlib:** Es la biblioteca base y su módulo más utilizado es **pyplot**.
- **Seaborn:** Librería de **alto nivel construida sobre matplotlib**, lo que simplifica la creación de gráficos comunes.
- **Plotnine:** Implementación de la gramática de los gráficos (*Grammar of Graphics*), basada en **ggplot2** de R.

Clasificación según Claus Wilke Propone clasificar las herramientas según el objetivo: gráficos para visualizar **cantidades y proporciones, distribuciones, relaciones entre dos variables cuantitativas y datos geoespaciales**.

Gráficos para visualizar distribuciones Muestran **cómo se reparten los valores de una variable**, con qué frecuencia y en qué rangos se concentran.

- **Gráfico de Bastones:** Ideal para **variables cuantitativas discretas** con pocos valores únicos. La altura de cada segmento representa la frecuencia absoluta o relativa. (Seaborn: `countplot`).
- **Histograma de Frecuencias:** Para variables cuantitativas con muchos valores. Agrupa los datos en **subintervalos (bins)** y grafica un rectángulo cuya área representa la frecuencia. (Seaborn: `histplot`).
- **Gráfico de Densidad:** Intenta visualizar la **distribución de probabilidad subyacente** mediante una curva continua y suave, utilizando el método de **estimación por kernel**. (Seaborn: `kdeplot`).
- **Comparar distribuciones entre grupos:** Útil para ver cómo se distribuye una variable cuantitativa en distintos grupos categóricos.
 - **Gráficos de densidad múltiples:** Curvas de densidad superpuestas por cada categoría.
 - **Boxplot Múltiple:** Compara la distribución resumiendo información (medianas, cuartiles), aunque oculta la densidad real.
 - **Strip plots o Jitter plots:** Representan **directamente todos los datos individuales**. Aplican ruido aleatorio (**jittering**) para dispersar los puntos y evitar que se superpongan. (Seaborn: `stripplot`).
 - **Violin plot:** Espeja un gráfico de densidad Kernel a cada lado. Representa una **combinación entre el boxplot (en su interior) y la densidad de las observaciones**. (Seaborn: `violinplot`).
 - **Ridgeline plot:** Visualiza los cambios en distribuciones mediante **curvas desplazadas verticalmente**, generando una apariencia de "cadena montañosa". Útil para grupos nominales o temporales.

Gráficos para visualizar conteos/proporciones Se utilizan cuando la variable es **cualitativa** y se busca describir frecuencias o proporciones.

- **Gráficos de Barras:** La longitud de cada barra es **proporcional al porcentaje o número de unidades** de la categoría.

- **Barras Agrupadas o Paralelas:** Permiten visualizar **dos variables categóricas al mismo tiempo** (resumen de tabla de contingencia) y mostrar distribuciones condicionales. (Seaborn: countplot con parámetro hue).
 - **Gráfico de Barras Apiladas (Stacked):** Muestra información conjunta apilando los valores sobre una sola barra.
 - **Gráfico de Sectores (Pie Chart):** Un círculo dividido donde **el área de cada sector es proporcional a la categoría**. Puede volverse engorroso si hay muchas categorías.
-

ANÁLISIS EXPLORATORIO DE DATOS: Visualizaciones (UNIDAD 4 - Parte 2)

Visualizar Series de Tiempo Para registrar la evolución temporal se utilizan **gráficos de líneas**. Conectar las observaciones individuales resalta el orden, identifica **tendencias, estacionalidades y cambios significativos** a lo largo del tiempo. (Seaborn: lineplot).

El Heatmap Es la representación de una matriz bidimensional de datos utilizando una **escala de colores**. Permite mostrar la magnitud de los valores y **resalta visualmente tendencias generales** que serían difíciles de detectar en una tabla tradicional.

Visualizar Asociaciones entre Variables Cuantitativas

- **Scatterplot:** Gráfico de puntos que permite representar la forma conjunta de observaciones de variables cuantitativas.
- **Pairplot:** Crea una **matriz de gráficos**. Muestra un scatterplot para cada combinación posible de variables y un histograma o gráfico de densidad en la diagonal para la distribución individual.

Correlograma Es un gráfico que resume las correlaciones (ej. Pearson) entre todas las variables utilizando la función **heatmap**.

- Para leerlo adecuadamente, **es fundamental utilizar una escala de colores divergente** (ej. de rojo a azul), con un punto medio neutro ($r=0$).
 - Los colores más fuertes en los extremos indican asociaciones lineales positivas o inversas más intensas.
 - **¡Importante!** Los correlogramas detectan relaciones lineales, pero pueden **ocultar patrones si las relaciones no son lineales**. Siempre se deben complementar con scatterplots.
-

ANÁLISIS EXPLORATORIO DE DATOS: Visualizaciones (UNIDAD 4 - Parte 3)

La Geodesia Es la ciencia que estudia la **forma y dimensiones de la Tierra** para poder ubicar puntos exactos y dar contexto espacial a los datos.

- **La Tierra como una esfera:** Es un modelo imperfecto, pero facilita los cálculos de profundidad y distancia.

- **La Tierra como elipsoide:** Es la forma geométrica que **mejor se adapta a la Tierra real**, considerando el achatamiento en los polos y ensanchamiento en el Ecuador causado por la rotación. El modelo más utilizado globalmente es el **WGS 84**.
- **La Tierra como geode:** Reproduce que la gravedad y masa terrestre no son uniformes, resultando en una **forma irregular con protuberancias y depresiones**.

El Datum Geodésico Es el sistema de referencia que indica **cómo se sitúa e interactúa el elipsoide respecto al centro de gravedad de la Tierra**.

- **Datums globales (Geocéntricos):** Su centro coincide con el centro de masas de la Tierra (ej. WGS 84, usado por el GPS).
- **Datums locales:** Alinean el elipsoide para que **ajuste de forma óptima a una región específica** (ej. Campo Inchauspe y Tapi Aike en Argentina).

Sistemas de Referencia de Coordenadas (CRS) y Proyecciones El CRS es vital para superponer información espacial correctamente.

- **Coordenadas Geográficas:** Sistema esférico donde un punto se localiza con valores angulares de **latitud y longitud**.
- **Proyecciones Cartográficas:** Proceso matemático para transformar los puntos de la esfera o elipsoide a una **superficie plana** (sistemas cartesianos X, Y).
 - **Proyecciones Cilíndricas:** Proyecta sobre un cilindro desenrollado (ej. Mercator). Distorsiona las áreas lejos del Ecuador.
 - **Proyecciones Cónicas:** Proyecta sobre un cono. Poco adecuada para representación de grandes áreas a nivel global (ej. Lambert).
 - **Proyecciones Planas o Azimutales:** Proyecta sobre un plano tangente a la esfera (ej. los polos).

Geopandas Librería de código abierto para datos georreferenciados construida sobre Pandas. Utiliza una columna espacial llamada geometry.

- **Geometrías espaciales:** **POINT** (ubicación o coordenada individual), **LINESTRING** (secuencia conectada de puntos, rutas/ríos), **POLYGON** (área cerrada, parcela/provincia) y **MULTIPOLYGON** (agrupamiento de polígonos, como un archipiélago).
- **Lectura de archivos:** El comando `gpd.read_file()` lee formatos como **GeoJSON**, **GML** o **Shapefiles**.
- **Representación:** Se visualizan con el método `.plot()` o solo sus límites con `.boundary.plot()`.
- **Manejo de CRS:** Para unificar datasets es crítico que compartan sistema; se modifican con `.to_crs()` (ej. pasar de EPSG:4326 en grados a EPSG:22174 proyectado en metros).

Librería Folium y Mapa Cloropleth

- **Folium:** Biblioteca para visualización de **mapas geoespaciales interactivos** en navegadores web.
- **Mapa Cloropleth:** Es una representación gráfica donde **las áreas geográficas están coloreadas en función de la intensidad de un valor o atributo específico**. Es muy útil para visualizar variaciones en conteos o densidad poblacional según divisiones regionales.

Aquí tienes la condensación completa de toda la información de la Unidad 6 sobre Regresión Lineal, manteniendo los títulos, subtítulos y destacando los conceptos fundamentales en negrita:

AJUSTES Y MODELOS: Presentación Introductoria

- **Modelando una Variable:** Si queremos modelar una sola variable (por ejemplo, la altura de las personas), un primer modelo estadístico puede estar dado por el **promedio o media aritmética** de los datos observados. Si disponemos de una segunda variable (por ejemplo, el peso), podemos incorporar esta información para generar predicciones mucho más ajustadas.
- **Modelo Estadístico:** Se define en Introducción a la Inteligencia Artificial como "**una representación simplificada de la realidad que constituye una herramienta para responder interrogantes y resolver problemas**".
- **Análisis de Regresión:** Bajo este nombre se engloba al conjunto de herramientas matemáticas que nos permiten explicar (modelar matemáticamente) el comportamiento de una **variable respuesta (Y)** a partir de la información proporcionada por una o más variables **explicativas o predictoras (X)**.

AJUSTES Y MODELOS: Regresión Lineal - Parte 1

El Modelo de Regresión

- La relación entre la variable respuesta (Y) y las variables predictoras (X) puede escribirse como: $Y = f(X) + \epsilon$.
- $f(X)$ es una **función fija pero desconocida** que captura la relación sistemática entre las variables.
- ϵ es el **término de error aleatorio**. Este término recoge todo lo que no está incluido en el modelo (variables omitidas, variaciones no medibles, etc.).

El Modelo de Regresión Lineal Simple

- Cuando es razonable suponer que $f(X)$ es una recta, el modelo toma la forma: $Y = \beta_0 + \beta_1 X + \epsilon$.
- **Coefficientes del modelo (Parámetros):**
 - β_0 (**Ordenada al origen**): Representa el valor promedio de la respuesta cuando la explicativa es igual a 0.
 - β_1 (**Pendiente**): Representa el cambio promedio en la variable respuesta cuando la variable explicativa aumenta en una unidad.

- Dado el error aleatorio, un valor de la predictora no especifica un valor exacto de la respuesta. El objetivo es **estimar estadísticamente $f(X)$ a partir de los datos**.

Estimación del Modelo y Método de Mínimos Cuadrados

- La ecuación estimada es: $\hat{y} = \beta_0 + \beta_1 x$, donde β_0 y β_1 son las estimaciones puntuales calculadas a partir de una muestra.
- **Método de Mínimos Cuadrados (OLS):** Es el método utilizado para hallar las estimaciones que corresponden a la recta que **mejor ajusta a los datos experimentales**.
- Busca encontrar los valores de los coeficientes que arrojen los **residuos lo más pequeños posibles** (la distancia vertical entre el punto observado y la recta predictora). Se logra minimizando la **suma de los residuos al cuadrado** (SC_{error} o **RSS**) derivando respecto a los parámetros e igualando a cero (ecuaciones normales).

Evaluando el Modelo: R^2

- **Coeficiente de Determinación (R^2):** Mide la **proporción de la variabilidad total en las observaciones de la variable respuesta (Y) que es explicada por el modelo**. Su rango de variación es entre **0 y 1**.
- Cuanto más cercano a 1 sea el valor, **mayor será la capacidad explicativa** del modelo. Un valor de 1 indica ajuste perfecto; un valor de 0 indica que el modelo no logra explicar nada de la variabilidad.
- **¡IMPORTANTE!** Un R^2 alto **no garantiza que el modelo sea adecuado**. Puede ser elevado en modelos no lineales o cuando hay valores atípicos influyentes. **Siempre debe acompañarse de exploración gráfica y análisis de residuos**.

Regresión Lineal Múltiple

- Se utiliza para extender el modelo e incorporar **múltiples variables explicativas** de manera simultánea para predecir la respuesta. Su ecuación suma distintos términos predictores: $Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \dots + \beta_p X_p + \epsilon$.

Generación de Variables Dummy (Incorporar Variable Cualitativa)

- Para incorporar predictores cualitativos (ej. sexo), se crea una **variable dummy o indicadora** que toma **valores numéricos** (por ejemplo, 1 si es macho y 0 si es hembra).
- Como resultado se obtienen **rectas de regresión ajustadas paralelas**, donde la diferencia en la predicción será un término aditivo que es independiente de la otra variable numérica (ej. la pendiente es la misma para ambos grupos, difieren en su ordenada al origen).

R^2 Ajustado y Otras Métricas para Evaluar el Modelo

- **R^2 Ajustado:** Dado que agregar variables al modelo siempre aumenta o mantiene igual el R^2 normal (incluso si aportan poca información), el R^2 ajustado **penaliza la complejidad del modelo**. Lo convierte en la **métrica útil para comparar modelos con distinto número de predictores**.

- **Error Cuadrático Medio (MSE):** Evalúa qué tan próximos se encuentran los valores predichos de los reales observados. Al estar elevado al cuadrado, esta métrica **penaliza fuertemente a los valores atípicos**.
- **Raíz del Error Cuadrático Medio (RMSE):** Es la raíz cuadrada del MSE. Su ventaja es que se expresa en las **mismas unidades que la variable respuesta (Y)**, siendo más utilizada en la práctica para reportar el error.
- **Error Absoluto Medio (MAE):** Toma la suma de los residuos en valor absoluto. Al no estar elevado al cuadrado, **es inherentemente más robusto a posibles distorsiones causadas por valores atípicos**. Se prefiere cuando el contexto justifica no penalizar de más los errores grandes.

AJUSTES Y MODELOS: Regresión Lineal: Inferencia y Predicción

¿Predicción, Inferencia o Ambas?

- **Predicción:** Interesa enfocarse en **obtener el valor de Y a partir de un conjunto de predictores X** (ej. ¿cuánto costará una casa dada sus características?). Suele tratar la función predictora $\hat{f}$ como una **caja negra**, ya que no interesa la forma matemática exacta, solo que sus predicciones sean precisas.
- **Inferencia:** Interesa **entender la relación matemática** entre los predictores y la respuesta (ej. ¿Qué predictores son los más importantes? ¿La relación es lineal o más complicada?). No se toma como una "caja negra".

Ensayar Hipótesis sobre los Parámetros

- Sirve para **tomar una decisión acerca del valor de un parámetro poblacional** en base a información de una muestra poblacional para ver si existe relación real o no.
- **Hipótesis nula (H_0):** No hay relación entre X e Y (matemáticamente, el coeficiente $\beta_1 = 0$).
- **Hipótesis alternativa (H_1):** Hay relación lineal entre X e Y (matemáticamente $\beta_1 \neq 0$).
- Para resolver el ensayo, se utiliza el **p-value (probabilidad asociada)**. Valores pequeños (típicamente **p-value < 0.05**) son **suficientes para considerar falsa la hipótesis nula (H_0)** y concluir que la relación es verdadera.

Más sobre la Calidad del Ajuste (Training vs. Test)

- **Training MSE (Datos de entrenamiento):** Se calcula utilizando los **mismos datos con los que el modelo fue entrenado**. Disminuye a medida que aumenta la complejidad del modelo (por sobreajuste).
- **Test MSE (Datos de testeo):** Se requiere para ver la calidad de las predicciones en **datos que el modelo no vio durante el ajuste**.

- **Overfitting (Sobreaajuste):** Ocurre cuando se elige el modelo basándose en minimizar el Training MSE en vez del Test MSE. Un modelo sobreajustado se enfoca tanto en los patrones o fluctuaciones aleatorias del conjunto de entrenamiento que **no generaliza bien al usar datos nuevos**, lo que causa un Test MSE grande. En el gráfico del ajuste, el Test MSE suele conformar un valle en "U" y **alcanza un valor mínimo en una situación de complejidad intermedia**.

REDFLAGS en una Regresión Lineal (Problemas y Supuestos de ajuste)

- **1. No linealidad de la relación respuesta-predictor:** El modelo asume relación lineal. Si la relación no es lineal, todas las inferencias serán sospechosas. Se identifica observando **Gráficos de residuos vs. valores predichos**, siendo útil utilizar **transformaciones no lineales** de los predictores (como $\log(X)$ o X^2) como posible solución.
- **2. Falta de normalidad:** Un supuesto muy importante es que **los errores ϵ tienen distribución normal**. Esto se detecta mediante el **Normal Q-Q Plot** de los residuos o mediante histogramas.
- **3. Heterocedasticidad:** Ocurre cuando los errores ϵ **tienen varianza o variabilidad inconstante**. En un gráfico de residuos vs. valores predichos suele presentar un **patrón tipo embudo**. Se puede solucionar aplicando transformaciones a la respuesta (como $\log(Y)$ o $\sqrt{Y}$).
- **4. Presencia de Outliers:** Un **punto atípico o lejano al valor predicho**. Aunque a veces no causan grandes problemas, **pueden influir de sobremanera en los cálculos y en la inferencia** dado que pesan fuertemente sobre el SC_{error} .
- **5. Colinearidad / Multicolinearidad:** Se da cuando dos o más variables predictoras **están íntimamente asociadas (correlacionadas)** entre sí. Dificulta la inferencia ya que no siempre es sencillo separar y determinar el efecto individual que cada predictor le aporta al modelo.

Gráficos de Residuos

- Para diagnosticar estos problemas se utilizan herramientas de Python gráficas como `sns.regplot` (para diagramas de dispersión con línea lowess) y **Normal Q-Q Plots** (de `statsmodels.api`), fundamentales para examinar la distribución y patrón de los residuos.

Bonus Track

- **Solución Cerrada:** El Método de Mínimos Cuadrados encuentra de forma **cerrada (con fórmulas y expresiones matemáticas exactas)** la solución que estima los parámetros para una regresión lineal simple.
 - **Algoritmo de Optimización Iterativo:** Alternativa para modelos más complejos donde no hay solución matemática directa. Se usa ampliamente en **machine learning / redes neuronales**. Utiliza algoritmos como el **descenso de gradiente**, que buscan un mínimo en la **función de costo o de pérdida** de manera progresiva ajustando pesos iterativamente.
-

MEDIDAS DE SIMILARIDAD ENTRE CADENAS

• SIMILARIDAD DE JARO

- Mide la similitud entre dos cadenas s_1 y s_2 .
- La fórmula es: $sim_j = \frac{1}{3} \left(\frac{m}{|s_1|} + \frac{m}{|s_2|} + \frac{m-t}{m} \right)$.
- Donde $|s_i|$ es la longitud de la cadena, m es el **número de caracteres que coinciden** y t es **la mitad del número de caracteres transpuestos**.
- Dos caracteres se consideran coincidentes si son iguales y **la distancia entre sus posiciones no supera** $\left\lfloor \frac{\max(|s_1|, |s_2|)}{2} \right\rfloor - 1$.

• SIMILARIDAD DE JARO-WINKLER

- Es una modificación a la fórmula de Jaro que **aumenta el rating de similitud si las cadenas comparadas comienzan con el mismo prefijo**.
- Fórmula: $sim_{jw} = sim_j + lp(1 - sim_j)$.
- l es la cantidad de caracteres que coinciden exactamente al comienzo (hasta un máximo de 4), y p es el factor de escalado (valor estándar $p = 0.1$).

• LIBRERÍA RAPIDFUZZ / IMPLEMENTACIÓN EN PYTHON

- RapidFuzz es una biblioteca de código abierto escrita en C++ con enlaces en Python, ideal para realizar **fuzzy string matching** y cálculos de similitud.
- Se importa como `from rapidfuzz.distance import Jaro, JaroWinkler` para calcular ambos métodos numéricamente.

• DISTANCIA DE LEVENSHTTEIN

- Es la métrica más básica de edición. Se define como el **menor número de operaciones de inserción, borrado o sustitución de un único carácter** necesarias para convertir una cadena en otra. Se invoca usando `rapidfuzz.distance import Levenshtein`.

• SIMILARIDAD (NORMALIZADA) DE LEVENSHTTEIN

- Análoga a las métricas anteriores, ofrece un valor normalizado entre 0 y 1.
- Fórmula: $sim_{lev} = 1 - \frac{dist_{lev}(s_1, s_2)}{\max(|s_1|, |s_2|)}$.
- Implementación en código: `Levenshtein.normalized_similarity`.

FUZZY JOINS

- Es una técnica utilizada para **matchear datos que pueden no coincidir perfectamente** debido a inconsistencias, omisiones o errores (se buscan coincidencias aproximadas).
- **Ejemplo:** Cruzar un padrón electoral con un registro de beneficiarios de subsidios donde los nombres no fueron escritos idénticos.
- Se compone de dos herramientas de rapidfuzz:
 - **fuzz:** provee las funciones de similaridad.
 - **process:** permite **buscar la mejor coincidencia** entre una cadena y una lista de candidatos aplicando la función elegida.
- **fuzz.token_sort_ratio()**
 - Aplica un preprocesamiento clave con tres pasos:
 1. **Tokenización:** divide las cadenas en tokens (palabras separadas por espacios).
 2. **Normalización:** convierte todos los tokens a minúsculas y elimina signos de puntuación (con el parámetro processor).
 3. **Ordenamiento alfabético:** los tokens se reordenan alfabéticamente y se vuelven a unir.
 4. **Cálculo de similaridad:** sobre las cadenas resultantes se aplica la métrica de distancia de Levenshtein normalizada (valor de 0 a 100).

DISTANCIAS Y MEDIDAS DE SIMILARIDAD EN DATOS NUMÉRICOS

- **MEDIR LA SIMILARIDAD ENTRE DATOS**
 - Cuantifica qué tan parecidos o distintos son los objetos. Útil para: **Clustering** (agrupar elementos homogéneos), **Detección de outliers** (identificar valores atípicos multivariados) y **Clasificación de vecinos más cercanos (KNN)**.
- **DISTANCIA EUCLÍDEA**
 - Es la métrica más popular. Representa la distancia euclídea entre observaciones.
 - Fórmula: $d_E(\mathbf{i}, \mathbf{j}) = \sqrt{(x_{1i} - x_{1j})^2 + \dots + (x_{pi} - x_{pj})^2}$.
 - **IMPORTANTE: Es muy sensible a las escalas de las variables.** Si tienen rangos muy diferentes, la de mayor rango dominará el cálculo. Siempre conviene **normalizar o estandarizar** los datos previamente.
 - Implementación: Con la librería SciPy (scipy.spatial.distance), se usa pdist() para sacar distancias por pares, y squareform() para convertirlas en una matriz cuadrada simétrica, que puede visualizarse con heatmaps.

- **DISTANCIA MANHATTAN**

- Llamada *City-Block* o *Taxicab*, mide la distancia como si uno se **desplazara por calles de cuadrícula en líneas rectas horizontales o verticales**.
- Fórmula: $d_{MHT}(\mathbf{i}, \mathbf{j}) = |x_{1i} - x_{1j}| + \dots + |x_{pi} - x_{pj}|$.

- **MANHATTAN vs. EUCLÍDEA**

- Manhattan tiene un **mejor comportamiento en espacios de alta dimensionalidad** (mitiga la maldición de la dimensionalidad, ya que pierde menos capacidad discriminativa).
- Preferible si los datos están ordenados en grilla/cuadrícula y funciona como una medida aditiva más adecuada.

- **DISTANCIA DE MAHALANOBIS**

- Mide qué tan lejos está una observación respecto del centro de una distribución (centroide).
- **Ventaja clave:** Al no tratar a todas las direcciones por igual, **tiene en cuenta la dispersión de los datos y la correlación entre las variables**. Direcciones con mayor variabilidad "pesan menos" en la distancia.
- Fórmula: $d_M(r_1, r_2) = \sqrt{(r_1 - r_2)^T \Sigma^{-1} (r_1 - r_2)}$, donde Σ^{-1} es la **inversa de la matriz de covarianza**.
- **Ventajas Principales:**
 1. **Considera la correlación** entre variables, ajustando la distancia según la forma de la "nube" de datos.
 2. **Es independiente de la escala (no requiere estandarizar previamente)** porque la multiplicación por la matriz incorpora la variabilidad automáticamente dándole un peso proporcional a su dispersión.
 3. Permite la **detección eficiente de valores atípicos** multivariados.
- *Ejemplo Iris:* En el dataset, al tener en cuenta la dispersión, la distancia Mahalanobis al centroide permite predecir correctamente la especie de una planta nueva, caso donde la distancia euclidiana fallaría al no considerar la forma de las clases.

SIMILARIDAD DE COSENO

- **REPRESENTACIÓN DE TEXTO: BoW**

- Para comparar textos matemáticamente, se usa *Bag of Words*, que representa cada documento como un **vector de frecuencias de términos** (term-frequency vector), donde cada dimensión indica cuántas veces aparece una palabra. Esto suele resultar en **vectores muy largos y con muchos ceros (dispersos/sparse)**.

- **El problema en el BoW:** La distancia euclidiana puede clasificar como diferentes a dos documentos con exactamente los mismos términos en las mismas proporciones simplemente por ser de distinta longitud. La similaridad recae en la temática, no en el tamaño.
- **SIMILARIDAD DE COSENO**
 - Resuelve el problema anterior: en lugar de medir la distancia entre extremos, **mide el ángulo entre los vectores**, lo que la hace **invariante a la longitud del documento**.
 - Fórmula: $sim_{cos}(i, j) = \frac{i \cdot j}{||i|| ||j||}$. Es el producto punto dividido por el producto de las normas (esto equivale a **normalizar ambos vectores antes de compararlos**).
 - **Valores resultantes:** Como las frecuencias son valores no negativos, el coseno varía entre 0 y 1. Si $sim_{cos} = 1$, los vectores apuntan en la misma dirección (gran composición temática común). Si $sim_{cos} = 0$, son ortogonales (no comparten términos).
 - **Cálculo en código:** Se importa como `from scipy.spatial.distance import cosine`. La librería devuelve la *distancia* coseno, por lo que para calcular la similitud se debe hacer la resta: **sim = 1 - cosine(i, j)**.