


ANÁLISIS EXPLORATORIO DE DATOS: Medidas de Resumen

UNIDAD 3 - Parte 2

Fundamentos de Ciencia de Datos 2026



MÉTRICAS DE CORRELACIÓN

CORRELACIÓN

El **análisis de correlación** tiene como objetivo estudiar el comportamiento conjunto de dos **variables aleatorias X e Y** , es decir, el grado en que ambas varían o “cambian” conjuntamente.

EJEMPLO

A lo largo de la clase, utilizaremos el dataset **penguins**, que contiene datos recolectados sobre una serie de 344 pingüinos de tres especies diferentes que anidan en una colonia del Archipiélago Palmer, en la Antártida.

EJEMPLO

El dataset puede cargarse directamente de la librería **seaborn**.

```
import seaborn as sns
df = sns.load_dataset('penguins')

df.head()
```

	species	island	bill_length_mm	bill_depth_mm	flipper_length_mm	body_length_mm
0	Adelie	Torgersen	39.1	18.7	181.0	332.0
1	Adelie	Torgersen	39.5	17.4	186.0	345.0
2	Adelie	Torgersen	40.3	18.0	195.0	366.0
3	Adelie	Torgersen	NaN	NaN	NaN	193.0
4	Adelie	Torgersen	36.7	19.3	193.0	344.0

FLIPPER LENGTH y BODY MASS

Si estuviéramos particularmente interesados en el ***largo de la aleta*** (**flipper_length_mm**) y en el ***peso*** (**body_mass_g**) de los pingüinos del Archipiélago Palmer, podríamos explorar ambas variables **individualmente**, haciendo un análisis descriptivo de la información con la que se cuenta para cada una (*clase anterior*).



¿Cómo podemos resumir la información sobre cada una de estas variables, individualmente?

```
print(df[['flipper_length_mm', 'body_mass_g']].describe().round(2))
```

	flipper_length_mm	body_mass_g
count	342.00	342.00
mean	200.92	4201.75
std	14.06	801.95
min	172.00	2700.00
25%	190.00	3550.00
50%	197.00	4050.00
75%	213.00	4750.00
max	231.00	6300.00

- 🌱 ¿Cuál es la longitud de aleta promedio de los pingüinos?
- 🔥 ¿Qué porcentaje de los pingüinos pesa más de 4750 g?
- 💡 ¿Cuál de los dos conjuntos de observaciones presenta mayor variabilidad?

También podemos representar ambas variables mediante **boxplots**:



🌱 ¿Qué nos dicen los gráficos sobre la simetría de cada set de datos? ¿Se observan valores atípicos?

FLIPPER LENGTH vs. BODY MASS

Pero quizás también puede interesarnos estudiar si existe algún tipo de **asociación** entre ambas.

El primer paso en el análisis conjunto de dos variables, antes de calcular cualquier métrica de correlación, es **GRAFICAR** los datos registrados de ambas medidas para todos los pingüinos del dataset.

¿Qué tipo de gráfico podemos construir para representar esa información?

GRÁFICO DE DISPERSIÓN (*Scatterplot*)

Un scatterplot muestra la relación entre dos **variables cuantitativas**. Los valores de una variable se grafican en el eje de abscisas y los de la otra, en el de las ordenadas. Cada par de observaciones viene representado en el gráfico por un **punto**.

```
sns.scatterplot(x = 'body_mass_g', y = 'flipper_length_mm', data = df) ;
```






GRÁFICO DE DISPERSIÓN (*Scatterplot*)



🧐 ¿Qué tipo de información nos brinda este gráfico sobre la relación entre la longitud la aleta y el peso de los pingüinos?

LA COVARIANCIA: intuición



Las medias de ambas variables **nos definen 4 cuadrantes**. ¿Qué ocurre con **la mayoría** de los productos $(x_i - \bar{x})(y_i - \bar{y})$?

LA COVARIANCIA (S_{xy})

La covariancia es una medida estadística que brinda información acerca del grado en que dos variables varían **linealmente** en forma conjunta.

Suponiendo que se cuenta con un conjunto de n pares de observaciones de dos variables, X e Y , se calcula de la siguiente forma:

$$S_{xy} = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})$$

LA COVARIANCIA (S_{xy})

La covariancia provee información acerca de la **dirección** de la asociación lineal entre las dos variables.

- Si la relación entre ambas variables es **directa** o **positiva**, $S_{xy} > 0$.
- Si la relación entre ambas variables es **inversa** o **negativa**, $S_{xy} < 0$.

Se puede demostrar que para dos variables **estadísticamente independientes** $S_{xy} = 0$ (σ_{xy} a nivel poblacional). Sin embargo, lo opuesto no es necesariamente cierto: 2 variables pueden tener una $S_{xy} = 0$ y aún así no ser estadísticamente independientes (asociaciones no lineales).

LA COVARIANCIA (S_{xy})

En nuestro ejemplo, podemos calcular la covariancia entre el largo de la aleta y la masa corporal utilizando el método **cov()** de la librería **Pandas**:

```
import pandas as pd

df[['body_mass_g', 'flipper_length_mm']].cov()
```

	body_mass_g	flipper_length_mm
body_mass_g	643131.077327	9824.416062
flipper_length_mm	9824.416062	197.731792

LIMITACIONES DE LA COVARIANCIA

- La covariancia **no tiene un rango de variación acotado**, por lo que su magnitud no indica nada con respecto a la **fuerza** de la asociación.
- La covariancia **es sensible a las unidades de medida de las variables**, por lo que puede hacerse arbitrariamente grande o pequeña si alguna de ellas es modificada.

COFICIENTE DE CORRELACIÓN DE PEARSON (r)

El **coeficiente de correlación lineal de Pearson** mide el grado de **asociación lineal** que existe entre dos variables cuantitativas continuas. Se calcula de la siguiente manera:

$$r = \frac{S_{xy}}{S_x S_y}$$

PROPIEDADES DE r


- Su **signo** indica si la relación es positiva o negativa.
- Está **acotado** ($-1 \leq r \leq 1$)
- Su **magnitud** es indicativa de la **fuerza de la asociación lineal** entre las variables: cuanto más cercano a 0, más débil es la asociación; cuanto más cercano a 1 se encuentre en valor absoluto, más fuertemente relacionadas están las variables.
- Si X e Y son dos **variables independientes**, entonces **$r = 0$** (ρ , a nivel poblacional). Sin embargo, **la recíproca no es cierta. $r = 0$** no implica necesariamente falta de asociación, sino que podría indicar **falta de linealidad en la relación entre las variables**.

PROPIEDADES DE r

Una regla práctica que puede emplearse como una guía para la interpretación de la intensidad de la relación es la siguiente (es un criterio arbitrario):

- $|r| < 0.5$: la relación lineal entre las variables es **débil**.
- $0.5 \leq |r| < 0.8$: la relación lineal entre las variables es **moderada**.
- $|r| \geq 0.8$: la relación lineal entre las variables es **intensa**.

EJEMPLOS



CÁLCULO DE r

Para calcular el r de Pearson en el ejemplo, podemos recurrir al método **corr()** de **Pandas**, que por *default* usa el método de Pearson (hay otros).

El resultado es una **matriz de correlación** que incluye las variables de interés.

CÁLCULO DE r


```
df[['body_mass_g', 'flipper_length_mm']].corr(method = 'pearson')
```

	body_mass_g	flipper_length_mm
body_mass_g	1.000	0.871
flipper_length_mm	0.871	1.000

A partir del valor obtenido, ¿cómo caracterizaríamos a la relación entre ambas variables?

PROBLEMAS DE INTERPRETACIÓN/USO DE r

Asumir que un alto valor de r implica causalidad. El hecho de que dos variables estén fuertemente correlacionadas no implica que una cause a la otra: **correlación no implica causalidad.**



© marketoonist.com

PROBLEMAS DE INTERPRETACIÓN/USO DE r


Calcular e informar el valor de r cuando la relación entre ambas variables no es lineal.

La correlación de Pearson mide fuerza de asociación **lineal** y no nos dice nada acerca de la intensidad de otro tipo de asociación (cuadrática, hiperbólica, cosenoidal, etc.). Por lo tanto, en estos casos calcular e informar r es inapropiado.

Por este motivo, es más que importante **graficar previamente** los datos para evaluar si tiene o no sentido calcular el coeficiente de correlación de Pearson.

PROBLEMAS DE INTERPRETACIÓN/USO DE r

Se ve afectado por la presencia de *outliers*. Un punto importante a marcar sobre el coeficiente de correlación de Pearson es que es una métrica bastante **sensible a la presencia de valores atípicos** en las observaciones, los cuales pueden distorsionar enormemente su valor y, en ciertos casos, conducir a conclusiones equivocadas.



CORRELACIÓN DE SPEARMAN

Vimos que el coeficiente de Pearson presenta algunas limitaciones: es sensible a la presencia de *outliers* y solo mide asociaciones lineales. El coeficiente de correlación de Spearman surge como una alternativa útil en ciertos contextos.

Se calcula *rankeando* los datos de las dos variables y luego computando el coeficiente de correlación de Pearson sobre los rangos asignados:

$$r_s = \frac{S_{RxRy}}{S_{Rx} S_{Ry}}$$

CORRELACIÓN DE SPEARMAN


El uso de rangos lo hace especialmente útil en tres situaciones:

- cuando se trabaja con **datos ordinales**,
- cuando la relación entre las variables es **monótona pero no lineal** (*toda relación lineal es monótona, pero no toda relación monótona es lineal*),
- cuando hay **outliers** que podrían distorsionar el coeficiente de correlación de Pearson.

 Una relación es monótona si, en términos generales, al aumentar una variable la otra tiende siempre a aumentar o siempre a disminuir.

PROPIEDADES DE r_s

- Provee una medida de la fuerza y la dirección de **asociaciones o relaciones monótonas** entre dos variables cuantitativas.



- Toma valores entre -1 y 1, donde $|r_s| = 1$ indica una relación monótona perfecta.

PROPIEDADES DE r_s

- Como está basado en **rangos**, es menos sensible a la presencia de *outliers* que el coeficiente de correlación de Pearson.
- Puede cuantificar o medir la fuerza de **cualquier tipo de relación monótona**, a diferencia del coeficiente de correlación de Pearson que sólo se emplea para relaciones lineales.


UN EJEMPLO

Supongamos que contamos con información sobre los tiempos de reacción y edad de un conjunto de 9 *gamers*:

Edad (años)	10	15	20	25	30	35	45	60
Tiempo (ms)	115	120	170	150	210	180	175	220

UN EJEMPLO

¿Cómo luce un *scatterplot* de estos datos?



🧐 ¿Qué características de la relación entre la edad y el tiempo de reacción se observan en el gráfico?


CÁLCULO DE r_s

Edad (años)	Tiempo (ms)	Redad	R _{tiempo}
10	115	1	1
15	120	2	2
20	170	3	5
25	150	4	3
30	210	5	7
35	180	6	6
45	165	7	4
60	220	8	8

Para calcular el r_s necesitamos tener los registros de las dos variables **rankeados**.

CÁLCULO DE r_s

¿Cómo luce el *scatterplot* de los rangos?



El r_s es el coeficiente de correlación lineal de Pearson calculado con los datos representados en el gráfico.

CÁLCULO DE r_s

Afortunadamente, si queremos utilizar **Pandas**, la librería se encarga de realizar internamente el proceso de asignación de rangos. Lo que tenemos que hacer es setear el parámetro **method='spearman'**.

```
data_gamers.corr(method = 'spearman')
```

	edad_anios	tiempo_ms
edad_anios	1.000	0.786
tiempo_ms	0.786	1.000

🤔 ¿Cómo podemos caracterizar a la relación entre ambas variables en base al valor obtenido?

MATRIZ DE COVARIANCIA/CORRELACIÓN

En el caso de que contemos con información sobre múltiples **variables cuantitativas** en el dataset, podemos construir una **matriz** en la que se muestren las **métricas de correlación** (covariancia, coeficientes de correlación de Pearson, Spearman, etc.) para todos los pares.

MATRIZ DE COVARIANCIA/CORRELACIÓN

De todas las variables con las que contamos en el dataset **penguins**, sólo son **variables cuantitativas** las siguientes:

- **bill_length_mm**
- **bill_depth_mm**
- **flipper_length_mm**
- **body_mass_g**

Seleccionaremos únicamente estas variables para construir nuestra matriz.

MATRIZ DE COVARIANCIA/CORRELACIÓN

Para construir la **matriz de covariancia**, utilizamos el método **cov()** de **Pandas**:

```
df[['bill_length_mm', 'bill_depth_mm', 'flipper_length_mm', 'body_mass_g']
```

	bill_length_mm	bill_depth_mm	flipper_length_mm	body_
bill_length_mm	29.807	-2.534	50.376	2605.1
bill_depth_mm	-2.534	3.900	-16.213	-747.3
flipper_length_mm	50.376	-16.213	197.732	9824.4
body_mass_g	2605.592	-747.370	9824.416	64313

🙄 ¿Qué mirar?

MATRIZ DE COVARIANCIA/CORRELACIÓN

Para construir la matriz de correlación de Pearson, utilizamos el método **corr()** de Pandas:

```
df[['bill_length_mm', 'bill_depth_mm', 'flipper_length_mm', 'body_mass_g']]
```

	bill_length_mm	bill_depth_mm	flipper_length_mm	body_
bill_length_mm	1.000	-0.235	0.656	0.595
bill_depth_mm	-0.235	1.000	-0.584	-0.472
flipper_length_mm	0.656	-0.584	1.000	0.871
body_mass_g	0.595	-0.472	0.871	1.000

¿Qué aporta en relación a la matriz de covariancia?


CORRELOGRAMA

Un **correlograma** es una representación gráfica que muestra las correlaciones entre todas las combinaciones posibles de variables en un conjunto de datos (es la versión gráfica de una matriz de correlación).

Podemos construirlo generando la matriz de correlación de nuestros datos y luego ploteándola con la función **heatmap()** de la librería **seaborn**. Hay algunas cuestiones impor tantes referidas a la escala de colores que las abordaremos en la próxima unidad.


CORRELOGRAMA

```
# Generamos la matriz de correlación
matriz = df[['bill_length_mm', 'bill_depth_mm', 'flipper_length_mm', 'body
# Construimos el heatmap
sns.heatmap(matriz, annot = True)
```




CORRELOGRAMA

A partir del gráfico, ¿cómo podríamos caracterizar la asociación entre los distintos pares de variables?



¿NOS ESTÁ ENGAÑANDO r ? 🤪🚩

El coeficiente de correlación de Pearson entre *profundidad de pico* y *longitud de aleta* es $r = -0.58$.



Pero...¿este valor es realmente un reflejo de lo que vemos en el gráfico de dispersión?