

ANÁLISIS EXPLORATORIO DE DATOS: Visualizaciones

UNIDAD 4 - Parte 2

Fundamentos de Ciencia de Datos 2025



VISUALIZAR SERIES DE TIEMPO

Una **serie temporal** es una secuencia de observaciones de una variable registradas en puntos específicos en el tiempo.

Para visualizar este tipo de datos, se suelen utilizar **gráficos de líneas**, en los que se conectan las observaciones individuales entre sí para resaltar el orden temporal.

Las líneas no representan datos en sí, sino que actúan como una guía visual que facilita la identificación de tendencias, estacionalidades y cambios significativos a lo largo del tiempo.

VISUALIZAR SERIES DE TIEMPO

Para ejemplificar, trabajaremos con el dataset **data_internet.csv**, del Banco Mundial, que contiene información acerca del porcentaje de personas con acceso a Internet a lo largo del tiempo en una serie de países.

Previamente, realizaremos tareas de limpieza y un filtrado de información (ver [notebook](#)) para considerar sólo los años a partir de 1990 y los datos correspondientes a los países que se encuentran en

lista_países:

```
lista_paises = ['Iceland', 'Norway', 'United Kingdom', 'Japan', 'Canada',  
'Germany', 'New Zealand', 'France', 'Israel', 'Argentina', 'United States',  
'Chile', 'Italy', 'Brazil', 'Mexico', 'South Africa', 'China', 'Algeria',  
'India', 'Kenia']
```

VISUALIZAR SERIES DE TIEMPO

Luego de realizadas las tareas de limpieza y adecuación, las primeras filas del dataset lucen de la siguiente manera:

	1990	1991	1992	1993	1994	1995	1996
Country							
Name							
Argentina	0.000	0.0000000	0.002993	0.029527	0.043706	0.086277	0.141955
Brazil	0.000	0.003288	0.012946	0.025498	0.037673	0.105138	0.450789
Canada	0.361	0.570386	0.915981	1.184558	2.378694	4.163525	6.760240
3 rows × 32 columns							

VISUALIZAR SERIES DE TIEMPO

Como primer ejemplo, supongamos que queremos construir un gráfico para visualizar la evolución del porcentaje de acceso a Internet de la población argentina en el periodo 1990-2021. Lo primero es filtrar esa información y darle forma de **DataFrame**.

```
data_argentina = data_internet_filtrado.loc['Argentina'].reset_index().rer
data_argentina.head()
```

	anio	porcentaje
0	1990	0.000000
1	1991	0.000000
2	1992	0.002993
3	1993	0.029527
4	1994	0.043706

VISUALIZAR SERIES DE TIEMPO

Atendiendo a que la columna **anio** es de tipo **object**, la transformamos en **int64** para poder realizar luego algunas modificaciones de escala en el gráfico:

```
data_argentina['anio'] = pd.to_numeric(data_argentina['anio'])
data_argentina.info()
```

```
<class 'pandas.core.frame.DataFrame'>
```

```
RangeIndex: 32 entries, 0 to 31
```

```
Data columns (total 2 columns):
```

#	Column	Non-Null Count	Dtype
---	--------	----------------	-------

---	-----	-----	----
-----	-------	-------	------

0	anio	32 non-null	int64
---	------	-------------	-------

1	porcentaje	32 non-null	float64
---	------------	-------------	---------


```
dtypes: float64(1), int64(1)
```

```
memory usage: 644.0 bytes
```

VISUALIZAR SERIES DE TIEMPO

Luego, utilizamos la función **Lineplot()** de **Seaborn** para representar estos datos en la forma de un gráfico de líneas:


```
sns.lineplot(x = 'anio', y = 'porcentaje', data = data_argentina);
```



VISUALIZAR SERIES DE TIEMPO

Sobre el gráfico anterior, podemos agregar los datos individuales en la forma de puntos seteando el parámetro **marker = 'o'**:

```
sns.lineplot(x = 'anio', y = 'porcentaje', marker = 'o', data = data_arger
```



VISUALIZAR SERIES DE TIEMPO

Supongamos ahora que queremos construir un gráfico para **comparar** la evolución del porcentaje de acceso a Internet en Argentina, India y Estados Unidos en el periodo 1990-2021. Lo primero es filtrar esa información y darle forma de **DataFrame** en formato largo:


```
data_paises = data_internet_filtrado.loc[['Argentina', 'India', 'United States']]
data_paises.head(3)
```

	Country Name	anio	porcentaje
0	Argentina	1990	0.000000
1	India	1990	0.000000
2	United States	1990	0.784729

VISUALIZAR SERIES DE TIEMPO

Podemos representar las observaciones correspondientes a cada país, seteando el parámetro **hue** = **'Country Name'** dentro de **sns.lineplot()**:

```
sns.lineplot(x = 'anio', y = 'porcentaje', hue = 'Country Name', marker =
```



VISUALIZAR SERIES DE TIEMPO

Para modificar características de la leyenda, como el título y las etiquetas, podemos agregar las siguientes líneas de código:

```
handles, labels = plt.gca().get_legend_handles_labels()
labels_espaniol = ['Argentina', 'India', 'Estados Unidos']
plt.legend(handles = handles, labels = labels_espaniol, title = 'País')
```

¿Qué es lo que hace este código?

plt.gca() devuelve el objeto **Axes** de los ejes actuales del gráfico (“*get current axes*”), es decir, el “área de dibujo” donde se colocan todos los elementos visuales como líneas, barras, etiquetas, leyendas, etc.

VISUALIZAR SERIES DE TIEMPO


En **Matplotlib**, **handles** son los objetos gráficos que representan los elementos que aparecen en la leyenda de un gráfico. Estos pueden ser líneas, barras, o cualquier otro tipo de marcador visual que aparece en el gráfico y que luego se incluye en la leyenda para identificar los distintos elementos.

Por su parte, los **Labels** son las etiquetas asociadas a cada uno de esos objetos (**handles**) que aparecen en la leyenda.

VISUALIZAR SERIES DE TIEMPO

Veamos el gráfico con estas modificaciones:

```
sns.lineplot(x = 'anio', y = 'porcentaje', hue = 'Country Name', marker =  
handles, labels = plt.gca().get_legend_handles_labels()  
labels_espaniol = ['Argentina', 'India', 'Estados Unidos']  
plt.legend(handles = handles, labels = labels_espaniol, title = 'País');
```



INCORPORAR A LOS DEMÁS PAÍSES

Si quisiéramos incluir a **todos los países en una única visualización**, realizar un gráfico como el anterior podría volverse poco práctico, ya que implicaría mostrar información para **20 países simultáneamente**, lo cual puede dificultar la lectura y la interpretación del gráfico:

```
print(lista_paises)
print(f'El total de países filtrados es: {len(lista_paises)}')

['Iceland', 'Norway', 'United Kingdom', 'Japan', 'Canada', 'Germany',
'New Zealand', 'France', 'Israel', 'Argentina', 'United States', 'Chile',
'Italy', 'Brazil', 'Mexico', 'South Africa', 'China', 'Algeria', 'India',
'Kenia']
El total de países filtrados es: 20
```

EL HEATMAP



El **heatmap** consiste en la representación gráfica bidimensional de una matriz de datos, en la que se utiliza una **escala de colores** para mostrar la magnitud de los valores/observaciones de una variable.

Su nombre deriva del uso tradicional de una paleta que recorre el espectro de colores cálidos a fríos.


Aunque esta visualización dificulta determinar los valores exactos que se muestran, hace un excelente trabajo al resaltar tendencias generales.

EL HEATMAP

Para construir un heatmap con los datos del porcentaje de acceso a Internet de los 20 países entre los años 1990 y 2021, utilizaremos la función **heatmap()** de la librería **Seaborn**. Esta función representa gráficamente la matriz de datos, asignando colores a cada celda según el valor del porcentaje de acceso a Internet correspondiente a cada país y año.

EL HEATMAP

Así luce el heatmap construido a partir de la matriz de datos:



EL HEATMAP

Este es el código que se utilizó para construir el gráfico de la slide anterior, que incluye el uso de la paleta **magma** (**cmap = 'magma'**) y modificaciones en los títulos de los ejes y de la escala de colores.

```
ax = sns.heatmap(data_internet_filtrado, cmap = 'magma', cbar_kws={'label':  
plt.xlabel('Año', fontweight = 'bold')  
plt.ylabel('País', fontweight = 'bold')  
cbar = ax.collections[0].colorbar  
cbar.ax.yaxis.label.set_fontweight('bold')  
plt.show()
```


EL HEATMAP

Una posible mejora del gráfico anterior consiste en ordenar los países según cuán temprano comenzaron a registrar un uso significativo de Internet.

👁️ Como ejercicio, modificar el heatmap construido para que los países se ordenen según el año en que **al menos el 20% de su población accedió a Internet**. Si bien este valor es arbitrario, permite realizar una mejor comparación del ritmo de adopción de Internet entre países.

EL HEATMAP


Este debería ser el resultado:



VISUALIZAR ASOCIACIONES ENTRE VARS. CUANTITATIVAS

Algunas clases atrás, utilizamos un Scatterplot para representar, en forma conjunta, las observaciones de las variables **flipper_length** y **body_mass** del dataset de los pingüinos del archipiélago Palmer:

```
data_penguins = sns.load_dataset('penguins')  
  
sns.scatterplot(x = 'body_mass_g', y = 'flipper_length_mm', data = data_penguins)
```




VISUALIZAR ASOCIACIONES ENTRE VARS. CUANTITATIVAS

El dataset incluye varias variables cuantitativas, por lo que deberíamos realizar un scatterplot diferente por cada par de variables que quisiéramos estudiar.

Afortunadamente, **Seaborn** ofrece la función **pairplot()**, que facilita la creación de una matriz de gráficos. Con un solo comando, podemos visualizar tanto la distribución individual de cada variable como las asociaciones entre pares, todo en un único gráfico.


```
sns.pairplot(vars = ['bill_length_mm', 'bill_depth_mm',  
                    'flipper_length_mm', 'body_mass_g'], data
```


VISUALIZAR ASOCIACIONES ENTRE VARS. CUANTITATIVAS



El resultado es una **matriz de scatterplots**, uno para cada combinación posible de las variables cuantitativas seleccionadas. En la diagonal, se muestra un histograma para visualizar la **distribución individual** de las observaciones de cada una de ellas.

VISUALIZAR ASOCIACIONES ENTRE VARS. CUANTITATIVAS



Si seteamos el parámetro **hue = 'species'** hacemos visible el hecho de que, en ciertos casos, existen diferencias marcadas entre las especies Adelie, Chinstrap y Gentoo.

La diagonal muestra ahora **gráficos de densidad** para cada variable individual según la especie.

CORRELOGRAMA


Un **correlograma** es una representación gráfica que muestra las correlaciones entre todas las combinaciones posibles de variables en un conjunto de datos (es la versión gráfica de una matriz de correlación de Pearson).

Podemos construirlo generando la matriz de correlación de nuestros datos y luego ploteándola con la función **heatmap()** de la librería **seaborn**.

CORRELOGRAMA

```
# Generamos la matriz de correlación
matriz = data_penguins[['bill_length_mm', 'bill_depth_mm', 'flipper_length_mm', 'body_mass_g']]

# Construimos el heatmap
sns.heatmap(matriz, annot = True);
```



CORRELOGRAMA


El gráfico anterior es la base de un correlograma, pero todavía tenemos algunas modificaciones importantes para hacerle para que sea adecuado.

En primer lugar, es fundamental utilizar una **escala de colores divergente**, la cual resulta de la combinación de dos escalas secuenciales unidas en un punto medio común, que generalmente se representa con un color claro. Este tipo de escala es ideal cuando necesitamos visualizar la desviación de los valores de los datos en una de dos direcciones con respecto a un punto medio neutral (en nuestro caso, $r = 0$).

CORRELOGRAMA

EJEMPLOS DE ESCALAS DIVERGENTES


1. **vlag**



2. **coolwarm**



3. **BrBG**



4. **RdYlGn**



CORRELOGRAMA

EJEMPLOS DE ESCALAS DIVERGENTES

5. **seismic**



6. **bwr**



7. Definidas manualmente

```
superior = sns.color_palette('Reds', 25)
inferior = sns.color_palette('Blues_r', 25)
sns.blend_palette(inferior + superior, n_colors = 25, as_cmap = True)
```




CORRELOGRAMA

Podemos configurar la paleta dentro del parámetro **cmap** de

sns.heatmap() y setear sus límites incluyendo **vmin = -1** y **vmax = 1**. Por ejemplo, con **BrBG**:


```
sns.heatmap(matriz, annot = True, cmap = 'BrBG', vmin = -1, vmax = 1);
```



CORRELOGRAMA

La última modificación importante es agregar un título a la escala de colores para indicar qué representan los valores.

```
sns.heatmap(matriz, annot = True, cmap = 'BrBG', vmin = -1, vmax = 1, cbar
```



CORRELOGRAMA

En el gráfico anterior, los colores verdes más fuertes se asocian con correlaciones lineales positivas más intensas, mientras que las tonalidades marrones más fuertes indican correlaciones lineales inversas más intensas.

¡IMPORTANTE! Si bien los correlogramas muestran información relevante sobre las asociaciones entre variables cuantitativas, al mismo tiempo **ocultan la existencia de patrones importantes en los datos y pueden llevarnos a sacar conclusiones incorrectas.** Por este motivo, siempre es conveniente complementarlos con una matriz de scatterplots y analizar si tiene sentido informar coeficientes de correlación lineales.